

Fitted Q-Iteration: Estimación de niveles de presas

Erika Rubí Jiménez Guzmán

2028-04-04

Table of contents

Resumen	3
Introduction	4
I Preliminares	5
1 Inteligencia Artificial	6
1.1 Machine Learning (Aprendizaje Automático)	6
2 Q-Learning	7
II Modelo Matemático	8
3 Modelo Matemático para Optimizar la Operación de un Sistema Hidroeléctrico.	9
3.1 Formulación como Proceso de Decisión de Markov (MDP)	9
3.1.1 Estructura Temporal	9
3.1.2 Espacio de estados y operador de discretización	10
3.1.3 Espacio de acciones	10
3.1.4 Dinámica de transición	10
3.2 Función de recompensa	11
3.2.1 Modelo hidráulico-energético linealizado	11
3.2.2 Estructura de penalizaciones	12
3.2.3 Ecuación de optimalidad de Bellman descontada	13
3.3 Aproximación numérica mediante Fitted Q-Iteration (FQI)	13
3.3.1 Motivación: maldición de la dimensionalidad y aprendizaje por refuerzo fuera de política	13
3.3.2 Iteración de Bellman empírica y estabilización numérica	13
3.3.3 Aproximación funcional por regresión no paramétrica	13
3.3.4 Criterios de convergencia y tolerancia computacional	13
3.4 Protocolo de simulación en lazo cerrado y evaluación operativa	13
3.4.1 Extracción de la política greedy óptima	13
3.4.2 Dinámica forward y proyección sobre restricciones físicas	14
3.4.3 Métricas de desempeño y validación estadística	14

3.5	Análisis teórico y propiedades del modelo	14
3.5.1	Contractividad del operador de Bellman en norma ℓ_∞	14
3.5.2	Cotas de error de aproximación y complejidad muestral	14
3.5.3	Alineación con el marco axiomático de Puterman (1994)	14
3.6	Limitaciones, extensiones y trabajo futuro	15
3.7	Conclusiones del capítulo	15
Referencias		18

Resumen

Aquí pondré un resumen de mi tesis, que se llama “Fitted Q-Iteration: Estimación de niveles de presas”.

Introduction

Esta será la introducción.

ejemplo de una cita Knuth (1984)

Part I

Preliminares

1 Inteligencia Artificial

La IA es...

1.1 Machine Learning (Aprendizaje Automático)

Disciplina dentro de la IA... Tipos principales

Definition 1.1 (Aprendizaje Supervisado). Se entrena con datos etiquetados...

Definition 1.2 (Aprendizaje No Supervisado). Se entrena con datos no etiquetados...

Definition 1.3 (Aprendizaje por Refuerzo). El agente aprende a través de la interacción con el entorno...

2 Q-Learning

Algoritmo de aprendizaje por refuerzo...

Definition 2.1 (Fitted Q-Iteration). Algoritmo Offline (aprende analizando el historial de experiencias)...

Part II

Modelo Matemático

3 Modelo Matemático para Optimizar la Operación de un Sistema Hidroeléctrico.

El objetivo de este capítulo es presentar una formulación rigurosa del problema de optimización de la operación de un sistema hidroeléctrico como un Proceso de Decisión de Markov (MDP), junto con una descripción detallada del algoritmo de Fitted Q-Iteration (FQI) utilizado para aproximar la política óptima. Se enfatizará la conexión entre los elementos matemáticos formales y su implementación numérica, así como la validación operativa mediante simulación en lazo cerrado.

3.1 Formulación como Proceso de Decisión de Markov (MDP)

3.1.1 Estructura Temporal

Se considera un horizonte temporal de operación compuesto por $T = 50$ años históricos, en donde cada uno de ellos se dividieron en $q = 24$ quincenas. Con el fin de reducir la dimensionalidad temporal y poder capturar la estacionalidad, se agruparon las quincenas en $M = 6$ etapas hidrológicas (segmentación temporal del año) mediante la siguiente función de agregación $\mu : \{0, \dots, q - 1\} \rightarrow \{0, \dots, M - 1\}$ definida por

$$\mu(q) = \begin{cases} 0, & 0 \leq q < 10 \\ 1, & 10 \leq q < 14 \\ 2, & 14 \leq q < 16 \\ 3, & 16 \leq q < 18 \\ 4, & 18 \leq q < 20 \\ 5, & 20 \leq q < 23 \end{cases} \quad (3.1)$$

así, la variable $m = \mu(q)$ representará la etapa hidrológica correspondiente a la quincena q . El índice temporal completo se denotará por como $\tau = (t, q)$ con $t \in \{0, \dots, T - 1\}$ y $q \in \{0, \dots, q - 1\}$.

3.1.2 Espacio de estados y operador de discretización

El sistema está compuesto por dos presas: [La Angostura](#) ($i = 1$) y [Malpaso](#) ($i = 2$). El volumen de almacenamiento de cada una de ellas en la quincena q del año t se representará por $V_{i,t,q} \in \mathbb{R}_{\geq 0} (Mm^3)$.

Dado que los datos históricos se utilizan para construir un conjunto de transición empírica, se introduce un operador de discretización uniforme del espacio de estados mediante el parámetro $\Delta = 600 Mm^3$. Así, el espacio de estados se define como $\mathcal{S} = \mathcal{S}_1 \times \mathcal{S}_2 \times \{0, \dots, 5\} = \{s = (s_1, s_2, m)\}$ en donde s_i representa el volumen discretizado de la presa i , tal estado discreto se obtiene mediante el operador de discretización $\mathcal{D} : \mathbb{R} \times \mathbb{N} \rightarrow \{0, \dots, N-1\}$ dado por

$$s_i = \mathcal{D}(V_{i,t,q}, N_i) = \min \left(\max \left(\left\lfloor \frac{V_{i,t,q}}{\Delta} + \frac{1}{2} \right\rfloor, 0 \right), N_i - 1 \right), \quad (3.2)$$

donde $N_1 = 27$ y $N_2 = 17$ son las capacidades discretas máximas de cada presa.

3.1.3 Espacio de acciones

Para cada etapa m , se define una unidad de extracción de agua $u_m = \{60, 150, 300, 300, 300, 150\}$, así la decisión de operación en la etapa m corresponderá a los niveles de turbinado k_1, k_2 . Cada nivel de turbinado se multiplica por la unidad de extracción u_m para obtener el volumen de agua extraído en cada presa. Por lo tanto, el espacio de acciones se define como

$$\mathcal{K}_m = \mathcal{K}_{1,m} \times \mathcal{K}_{2,m},$$

donde $\mathcal{K}_{i,m}$ representa el conjunto de niveles de turbinado disponibles para la presa i en la etapa m .

Una acción denotada por $a = (k_1, k_2)$, representará el nivel de turbinado aplicado simultáneamente en ambas presas. Por ejemplo, suponga que $m = 0$ entonces

$$\mathcal{K}_1, \mathcal{K}_2 = \{0, 1, \dots, 7\},$$

y así $a = (3, 5)$ significaría que Angostura turбина $3 \times 60 = 180 Mm^3$ de agua y Malpaso turбина $5 \times 60 = 300 Mm^3$ de agua.

3.1.4 Dinámica de transición

La ecuación de transición continua tras la operación del sistema se define por

$$V_{i,t,q+1} = V_{i,t,q} + W_{i,t,q+1} - k_i u_m, \quad q < 23 \quad (3.3)$$

donde $V_{i,t,q}$ representa el volumen almacenado en la presa i antes de tomar la acción de turbinado y $W_{i,t,q+1}$ representa el afluente neto (caudal de ingreso) para la presa i en la quincena $q + 1$ del año t .

Cuando $q = 23$, la transición se define por

$$V_{i,t+1,0} = V_{i,t,23} + W_{i,t+1,0} - k_i u_m. \quad (3.4)$$

En ambos casos, el volumen discretizado siguiente se obtiene aplicando el operador de discretización $\mathcal{D}$ al volumen resultante, es decir,

$$s'_i = \mathcal{D}(V_{i,t,q+1}, N_i),$$

mientras que la etapa evoluciona mediante $m' = (m + 1) \bmod M$.

Por lo tanto, el estado discreto siguiente está dado por

$$s' = (s'_1, s'_2, m').$$

Desde el punto de vista de Puterman (1994), la transición de MDP se define mediante una función de probabilidad condicional

$$\mathbb{P}(s'|s, a), \quad (3.5)$$

la cual especifica la probabilidad de transicionar al estado s' dado que se tomó la acción a en el estado s . Sin embargo, en el presente trabajo no se modela una distribución analítica explícita, por lo que en la práctica se construye un dataset empírico basado en datos históricos

$$\text{Trans} = \{(s, a, r, s')\}$$

en donde cada (s, a, r, s') representa una experiencia de transición observada en los datos históricos, con r representando la recompensa obtenida al tomar la acción a en el estado s y transicionar a s' . Este enfoque se alinea con un esquema de **Batch Reinforcement Learning**.

3.2 Función de recompensa

3.2.1 Modelo hidráulico-energético linealizado

La energía generada depende del volumen de agua turbinado y una aproximación lineal de la altura hidráulica. Para cada presa i , se define la función de altura

$$H_i(s_i, s'_i) = 10(s_i + s'_i + 2) \quad (3.6)$$

tal expresión corresponde a un modelo lineal basado en estados discretizados, el término $+2$ se introduce para evitar alturas nulas en estados con bajo volumen.

Sea $\eta = 0.9$ eficiencia de conversión hidráulica a eléctrica, y $g = 9.81 \text{ m/s}^2$ aceleración de la gravedad, entonces la energía generada por la presa i al tomar la acción a en el estado s y transicionar a s' se define por

$$E_i(s, a, s') = \frac{\eta g H_i(s_i, s'_i) (k_i u_m \times 10^6)}{3600 \times 10^6}, \quad (3.7)$$

así, la energía total generada por el sistema es

$$E = E_1 + E_2. \quad (3.8)$$

3.2.2 Estructura de penalizaciones

La recompensa incorpora penalizaciones para garantizar el cumplimiento de restricciones operativas. Se definen las siguientes penalizaciones:

- Penalización por derrame: si $V_{i,t,q+1} > N_i \Delta$ se aplica

$$\Pi_{derr} = C_{derr} \cdot \left(\frac{V_{i,t,q+1} - N_i \Delta}{\Delta} \right) \quad (3.9)$$

- Penalización por déficit de agua: si $V_{i,t,q+1} < 0$ se aplica

$$\Pi_{def} = C_{def} \quad (3.10)$$

- Penalización por violación de curva guía: si $s'_i < \text{CG}_i(m)$ se aplica

$$\Pi_{CG} = C_{CG} \cdot (s'_i - \text{CG}_i(m)) \quad (3.11)$$

- Penalización por niveles críticos: si $s'_i \geq N_i - 1$ se aplica

$$\Pi_{crit} = C_{crit} \quad (3.12)$$

donde $C_{derr}, C_{def}, C_{CG}, C_{crit}$ son constantes de penalización ajustadas empíricamente, y $\text{CG}_i(m)$ representa la curva guía para la presa i en la etapa m .

La función de recompensa total se define por

$$\mathcal{R}(s, a, s') = E - \Pi_{derr} - \Pi_{def} - \Pi_{CG} - \Pi_{crit}. \quad (3.13)$$

3.2.3 Ecuación de optimalidad de Bellman descontada

3.3 Aproximación numérica mediante Fitted Q-Iteration (FQI)

3.3.1 Motivación: maldición de la dimensionalidad y aprendizaje por refuerzo fuera de política

- Justificación de no usar iteración de política clásica o programación dinámica exacta.
- Referencias a Ernst et al. (2005), Antos et al. (2008).

3.3.2 Iteración de Bellman empírica y estabilización numérica

- Cálculo de $y_n^{(j)}$, operador de truncamiento $\text{clip}(\cdot)$, y manejo de divergencias en métodos *off-policy*.
- **Elemento matemático sugerido:** *Algoritmo X.1* en pseudocódigo estructurado (estilo ACM/IEEE).

3.3.3 Aproximación funcional por regresión no paramétrica

- Problema de mínimos cuadrados empírico sobre $\mathcal{F}$, hiperparámetros (árboles, profundidad, *min_samples_leaf*), y justificación de *Extra Trees* (reducción de varianza, sesgo controlado).
- Comentario sobre universalidad y capacidad de aproximación de bosques aleatorios.

3.3.4 Criterios de convergencia y tolerancia computacional

- Norma media en conjunto fijo $\mathcal{S}_{\text{test}}$, umbral $\varepsilon = 10^{-3}$, y detección temprana de estancamiento.
- **Elemento matemático sugerido:** *Criterio de parada X.1* con justificación numérica (estabilidad de punto fijo aproximado).

3.4 Protocolo de simulación en lazo cerrado y evaluación operativa

3.4.1 Extracción de la política greedy óptima

- Definición de $\pi^*(s) \in \arg \max_{a \in \mathcal{A}_s} \hat{Q}^*(s, a)$ y discusión sobre no unicidad y desempate determinista.

3.4.2 Dinámica forward y proyección sobre restricciones físicas

- Simulación sobre series históricas, proyección $\min\{\max\{\tilde{V}_i, 0\}, N_i\Delta V\}$, y manejo de fronteras anuales.
- Comentario sobre desacople entre entrenamiento (penalizaciones blandas) y evaluación (restricciones duras).

3.4.3 Métricas de desempeño y validación estadística

- Energía esperada por reserva, derrames acumulados, violaciones de curvas guía, y análisis de varianza interanual.
- **Elemento sugerido:** *Tabla X.1* resumen de parámetros operativos y *Figura X.1* trayectoria típica de volúmenes y energía.

3.5 Análisis teórico y propiedades del modelo

3.5.1 Contractividad del operador de Bellman en norma ℓ_∞

- **Lema X.1:** $\|\mathcal{T}Q_1 - \mathcal{T}Q_2\|_\infty \leq \gamma\|Q_1 - Q_2\|_\infty$.
- Breve demostración usando la propiedad $\max - \min \leq \max(|\cdot|)$ y citando Puterman (1994, Thm. 6.2.3).

3.5.2 Cotas de error de aproximación y complejidad muestral

- Descomposición del error: $\|\hat{Q}^* - Q^*\|_\infty \leq \frac{2\gamma}{(1-\gamma)^2}\epsilon_{\text{approx}} + \mathcal{O}(N^{-1/2})$.
- Comentario sobre trade-off sesgo-varianza en $\mathcal{F}$ y efecto del tamaño de muestra histórico.

3.5.3 Alineación con el marco axiomático de Puterman (1994)

- **Tabla X.2** correspondencia código $\leftrightarrow$ teoría MDP.
- Discusión sobre validez de supuestos: horizonte infinito, descuento, espacios finitos, kernel empírico como aproximación de $\mathcal{P}$.

3.6 Limitaciones, extensiones y trabajo futuro

- Limitaciones: discretización fija, modelo lineal de altura, ausencia de incertidumbre explícita en afluentes, penalizaciones estáticas.
- Extensiones: curvas cota-volumen reales, kernels estocásticos (ARIMA, copulas), FQI con regularización, métodos de política primal-dual para restricciones duras.
- Aplicación a otros sistemas multireservorio y escalabilidad computacional.

3.7 Conclusiones del capítulo

- Síntesis de contribuciones matemáticas y numéricas.
- Reafirmación de la coherencia entre formulación teórica, implementación algorítmica y validación operativa.
- Declaración de cierre alineada con los objetivos de la tesis.

4

5

Referencias

Knuth, Donald E. 1984. “Literate Programming.” *Comput. J.* (USA) 27 (2): 97–111. <https://doi.org/10.1093/comjnl/27.2.97>.

Puterman, Martin L. 1994. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. Wiley Series in Probability and Statistics. John Wiley & Sons. <https://doi.org/10.1002/9780470316887>.