

Fitted Q-Iteration: Estimación de niveles de presas

Erika Rubí Jiménez Guzmán
Asesor: Dr. Yofre Hernán García Gómez

2026-09-18

Table of contents

Resumen	3
Introduction	4
I Preliminares	5
1 Fundamentos Matemáticos	6
1.1 Inteligencia Artificial (IA)	6
1.1.1 Aprendizaje Automático	6
2 Fundamentos Hidráulicos	9
II Modelo Matemático	10
3 Modelo Matemático para Optimizar la Operación de un Sistema Hidroeléctrico.	11
3.1 Formulación como Proceso de Decisión de Markov (MDP)	11
3.1.1 Estructura Temporal (T)	11
3.1.2 Espacio de estados ($\mathcal{S}$)	12
3.1.3 Espacio de acciones ($\mathcal{A}$)	13
3.1.4 Dinámica de transición ($\mathbb{P}$)	14
3.1.5 Función de recompensa ($\mathcal{R}$)	15
3.2 Ecuación de optimalidad de Bellman	16
3.3 Aproximación numérica mediante Fitted Q-Iteration (FQI)	17
3.3.1 Conjunto de aprendizaje “parcialmente libre de modelo”	17
3.3.2 Iteración de Bellman empírica	18
3.3.3 Aproximación del operador de maximización sobre estados continuos	18
3.3.4 Aproximación funcional por regresión no paramétrica (ExtraTrees)	19
3.3.5 Criterio de paro basado en desempeño simulado	20
3.4 Política óptima y simulación operativa	21
3.4.1 Métricas de desempeño y validación estadística	22
3.5 Conclusiones del capítulo	23
Referencias	26

Resumen

Aquí pondré un resumen de mi tesis, que se llama “Fitted Q-Iteration: Estimación de niveles de presas”.

Introduction

Esta será la introducción.

ejemplo de una cita Puterman (1994).

Part I

Preliminares

1 Fundamentos Matemáticos

1.1 Inteligencia Artificial (IA)

La **Inteligencia Artificial (IA)** es un campo de estudio que se centra en la creación de sistemas capaces de realizar tareas que normalmente requieren inteligencia humana. La IA combina diversas disciplinas, incluyendo matemáticas, estadísticas, informática y neurociencia, para desarrollar algoritmos y modelos que permiten a las máquinas aprender, razonar y tomar decisiones de manera autónoma.

Este campo está dividido en varias subáreas, cada una con su enfoque y aplicaciones específicas. Entre las más destacadas se encuentran el **Aprendizaje Automático (Machine Learning)**, **Aprendizaje Profundo (Deep Learning)**, **Procesamiento del Lenguaje Natural**, **Visión por Computadora**, **Robótica**, entre otras. Cada una de estas subáreas utiliza diferentes técnicas y enfoques para abordar problemas complejos y mejorar la capacidad de las máquinas para interactuar con el mundo que las rodea.

1.1.1 Aprendizaje Automático

En este subcampo de la Inteligencia Artificial, las máquinas aprenden a partir de datos, similar a como lo hacemos nosotros, permitiéndoles mejorar con la experiencia. El aprendizaje automático se basa en algoritmos que identifican patrones y relaciones en los datos, lo que permite a las máquinas hacer predicciones o tomar decisiones sin ser explícitamente programadas para cada tarea específica. Este enfoque ha revolucionado diversas industrias, desde la medicina hasta la economía, al proporcionar herramientas más eficientes y precisas para el análisis de datos y la toma de decisiones.

El aprendizaje automático se clasifica en tres categorías principales: **Aprendizaje Supervisado**, **Aprendizaje No Supervisado** y **Aprendizaje por Refuerzo**, cada una con sus propias técnicas y aplicaciones. Estas categorías permiten abordar diferentes tipos de problemas y desafíos, desde la clasificación de datos hasta la optimización de estrategias en entornos dinámicos.

Definition 1.1 (Aprendizaje Supervisado). Esta categoría se basa en utilizar conjuntos de datos etiquetados (datos de entrada con sus correspondientes salidas) para entrenar modelos

matemáticos que puedan identificar patrones y a partir de ellos predecir resultados futuros sobre datos nuevos.

Este tipo de aprendizaje es principalmente utilizado en:

- **Tareas de clasificación:** los modelos predicen la clase a la que pertenece cada dato. Por ejemplo, identificar si un correo electrónico es spam o no.
- **Regresión:** predicen valores numéricos a partir de datos de entrada. Por ejemplo, predecir el precio de una vivienda basado en sus características.

Definition 1.2 (Aprendizaje No Supervisado). A diferencia del aprendizaje supervisado, en este tipo de aprendizaje no se utilizan datos etiquetados. En su lugar, los algoritmos buscan patrones ocultos o agrupaciones dentro de los datos. Estos modelos son utilizados para tareas específicas como:

- **Agrupamiento (Clustering):** los modelos identifican grupos de datos similares entre sí. Por ejemplo, segmentar clientes en diferentes grupos según sus comportamientos de compra.
- **Reducción de dimensionalidad:** los modelos simplifican los datos manteniendo la mayor cantidad de información posible. Por ejemplo, reducir el número de variables en un conjunto de datos para facilitar su análisis.

Definition 1.3 (Aprendizaje por Refuerzo). En este tipo de aprendizaje automático, los agentes autónomos aprenden a tomar decisiones a partir de la interacción con un entorno en el cual reciben recompensas o penalizaciones según sus acciones. A continuación se presentan los conceptos fundamentales de este tipo de aprendizaje

- **Agente:** es el sistema que toma decisiones y aprende de la experiencia.
- **Entorno:** en donde el agente opera y recibe retroalimentación.
- **Estado:** Situación actual del agente en el entorno.
- **Acción:** Decisión que el agente toma en un estado determinado.
- **Recompensa:** Retroalimentación que el agente recibe después de realizar una acción, indicando si fue beneficiosa o no.
- **Política:** Estrategia que el agente sigue para decidir qué acción tomar en cada estado.

El aprendizaje por refuerzo se centra esencialmente en la relación entre un agente, entorno y el objetivo (lo que se desea lograr). La literatura formula esta relación en términos de un **Proceso de Decisión de Markov (MDP)**.

Véase IBM (2025) para más información sobre estos tipos de aprendizaje y sus aplicaciones.

1.1.1.1 Q-Learning

Existen distintos algoritmos de aprendizaje por refuerzo, entre los cuales se encuentra el **Q-Learning**, este permite a un agente aprender a tomar decisiones en un entorno para maximizar una recompensa acumulada a lo largo del tiempo. Este modelo es model-free, es decir, no requiere un modelo del entorno para aprender, sino que se basa en la experiencia directa del agente a través de la exploración y explotación de su entorno.

2 Fundamentos Hidráulicos

Algoritmo de aprendizaje por refuerzo...

Definition 2.1 (Fitted Q-Iteration). Algoritmo Offline (aprende analizando el historial de experiencias)...

Part II

Modelo Matemático

3 Modelo Matemático para Optimizar la Operación de un Sistema Hidroeléctrico.

El objetivo de este capítulo es presentar una formulación rigurosa del problema de optimización de la operación de un sistema hidroeléctrico como un Proceso de Decisión de Markov (MDP), junto con una descripción detallada del algoritmo de Fitted Q-Iteration (FQI) utilizado para aproximar la política óptima. Se enfatizará la conexión entre los elementos matemáticos formales y su implementación numérica, así como la validación operativa mediante simulación en lazo cerrado.

3.1 Formulación como Proceso de Decisión de Markov (MDP)

Siguiendo la notación de Puterman (1994), se define el MDP como la colección de objetos

$$\{(T, \mathcal{S}, \mathcal{A}, \mathbb{P}, \mathcal{R})\},$$

donde cada componente se especifica a continuación.

3.1.1 Estructura Temporal (T)

Se considera un horizonte temporal de operación compuesto por $T = 50$ años históricos (periodo 1959–2008), en donde cada uno de ellos se divide en $q = 24$ quincenas. Con el fin de reducir la dimensionalidad temporal y capturar la estacionalidad, las quincenas se agrupan en $M = 6$ etapas hidrológicas mediante la función de agregación $\mu : \{0, \dots, 23\} \rightarrow \{0, \dots, 5\}$ definida por

$$\mu(q) = \begin{cases} 0, & 0 \leq q < 10 \\ 1, & 10 \leq q < 14 \\ 2, & 14 \leq q < 16 \\ 3, & 16 \leq q < 18 \\ 4, & 18 \leq q < 20 \\ 5, & 20 \leq q \leq 23 \end{cases} \quad (3.1)$$

de modo que $m = \mu(q)$ es la etapa hidrológica correspondiente a la quincena q . Esta partición reproduce exactamente la agrupación implementada en el código (`etapas_quinc`), verificada como correcta.

Dos resoluciones temporales distintas. Es indispensable distinguir, desde ahora, dos usos diferentes de esta estructura temporal: (i) para **construir el conjunto de aprendizaje** del algoritmo de FQI (Sec. Section 3.3.1), la afluencia se agrega a nivel de *etapa* ($M = 6$ decisiones por año) y no se recorre la serie quincena por quincena; (ii) para **desplegar y evaluar la política** ya aprendida (Sec. Section 3.4), la decisión sí se reconsulta en cada una de las 24 quincenas del año, usando en cada una la afluencia real de esa quincena, aunque los parámetros vigentes (capacidad máxima, curva guía, grilla de acción) sean los de la etapa $m = \mu(q)$ que la contiene.

3.1.2 Espacio de estados ($\mathcal{S}$)

El sistema está compuesto por dos presas: **La Angostura** ($i = 1$) y **Malpaso** ($i = 2$). El volumen almacenado en la presa i en la quincena q del año t se representa por $V_{i,t,q} \in \mathbb{R}_+ \cup \{0\}$ (millones de metros cúbicos, Mm^3).

A diferencia del enfoque de Programación Dinámica Estocástica (PDE), en el que el almacenamiento se discretiza en celdas y el estado es un índice entero, **en FQI el almacenamiento se mantiene como variable continua**. El parámetro $\Delta = 600 \text{ Mm}^3$ (el cual permite subdividir la capacidad de almacenamiento de cada presa) y los enteros $N_1 = 27$, $N_2 = 16$ (capacidades discretas máximas de cada presa) —heredados de la discretización de la PDE precedente— no se usan aquí para discretizar el estado, sino únicamente para fijar las **capacidades máximas continuas** de cada presa,

$$V_{1,\max} := N_1 \Delta = 16,200 \text{ Mm}^3, \quad V_{2,\max} := N_2 \Delta = 9,600 \text{ Mm}^3, \quad (3.2)$$

y para convertir a volumen la curva guía, definida originalmente en unidades de índice (Sec. Section 3.1.5).

El espacio de estados del MDP es entonces

$$\begin{aligned} \mathcal{S} &= [0, V_{1,\max}] \times [0, V_{2,\max}] \times \{0, \dots, 5\} \\ &= \{s = (s_1, s_2, m) : s_i \in [0, V_{i,\max}], i = 1, 2, m \in \{0, \dots, 5\}\}. \end{aligned} \quad (3.3)$$

Grilla gruesa de referencia. Aunque el estado en sí no se discretiza, tanto la construcción del conjunto de aprendizaje (Sec. Section 3.3.1) como la aproximación del operador de maximización (Sec. Section 3.3.3) requieren evaluar funciones en un conjunto finito y manejable de puntos de almacenamiento. Se define para ello una grilla de referencia de $N_s = 9$ puntos equiespaciados por presa,

$$\mathcal{S}_i^{\text{grid}} := \left\{ 0, \frac{V_{i,\max}}{8}, \frac{2V_{i,\max}}{8}, \dots, V_{i,\max} \right\}, \quad i = 1, 2, \quad (3.4)$$

con paso $V_{1,\max}/8 = 2,025 \text{ Mm}^3$ y $V_{2,\max}/8 = 1,200 \text{ Mm}^3$ respectivamente. Esta grilla **no es una discretización del MDP**: es un dispositivo de muestreo y de cómputo; la política final se evalúa siempre en el valor continuo real del almacenamiento.

3.1.3 Espacio de acciones ($\mathcal{A}$)

Para cada etapa m se define una unidad de extracción de agua $u_m = (100, 200, 300, 300, 400, 250)$ Mm^3 , y un conjunto de índices factibles $\mathcal{K}_{i,m}$ heredado de la grilla de decisión de la PDE:

$$\begin{aligned}\mathcal{K}_0 &= \{0, \dots, 20\}, & \mathcal{K}_1 &= \{0, \dots, 15\}, & \mathcal{K}_2 &= \{0, \dots, 7\}, \\ \mathcal{K}_3 &= \{0, \dots, 9\}, & \mathcal{K}_4 &= \mathcal{K}_5 = \{0, \dots, 12\}.\end{aligned}$$

(idéntico para ambas presas en cada etapa). Estos índices **no enumeran directamente el conjunto de acciones factibles del FQI**: se usan únicamente para obtener la cota superior del turbinado factible en la etapa,

$$A_{\max}(m) := u_m \cdot \max(\mathcal{K}_m). \quad (3.5)$$

Por ejemplo, para $m = 0$: $u_0 = 100$, $\max(\mathcal{K}_0) = 20$, de modo que $A_{\max}(0) = 2,000 \text{ Mm}^3$ (así, un par de índices como $(k_1, k_2) = (3, 5)$ de la PDE correspondería a turbinar 300 y 500 Mm^3 respectivamente —dentro de la cota—, pero el FQI no restringe la acción a estos múltiplos enteros de u_m).

El **espacio de acciones factible** para el MDP continuo es el intervalo

$$\mathcal{A}_m := [0, A_{\max}(m)] \times [0, A_{\max}(m)] = \{a = (a_1, a_2)\} \quad (3.6)$$

con a_i el volumen turbinado en la presa i , continuo. Al igual que con el estado, para fines de muestreo (Sec. Section 3.3.1) y de maximización aproximada (Sec. Section 3.3.3) este intervalo se discretiza en una grilla gruesa de $N_a = 9$ puntos equiespaciados,

$$\mathcal{A}_m^{\text{grid}} := \left\{0, \frac{A_{\max}(m)}{8}, \dots, A_{\max}(m)\right\}, \quad |\mathcal{A}_m^{\text{grid}}| = 9. \quad (3.7)$$

Table 3.1: Capacidad máxima de turbinado por etapa, calculada según Equation 3.5.

Etapla m	u_m (Mm^3)	$\max(\mathcal{K}_m)$	$A_{\max}(m)$ (Mm^3)
0	100	20	2,000
1	200	15	3,000
2	300	7	2,100
3	300	9	2,700
4	400	12	4,800
5	250	12	3,000

Los valores de u_m y $\mathcal{K}_m$ se seleccionaron, en el diseño original de la PDE, para que $A_{\max}(m)$ no exceda la capacidad instalada de las plantas ni los caudales históricos máximos registrados; esa cota se conserva íntegramente en el modelo continuo de FQI.

3.1.4 Dinámica de transición ($\mathbb{P}$)

Balance de masa a nivel de etapa (usado para el conjunto de aprendizaje). Para construir las transiciones de entrenamiento (Sec. Section 3.3.1), la afluencia se agrega a nivel de etapa: sea

$$\xi_{i,t,m} := \sum_{q: \mu(q)=m} W_{i,t,q} \quad (3.8)$$

la afluencia histórica del año t agregada sobre las quincenas de la etapa m (para la presa i), donde $W_{i,t,q}$ es el afluente neto observado en la quincena q del año t (dato histórico). El balance de masa teórico (sin restricción de capacidad) al aplicar la acción $a_i \in \mathcal{A}_m^{\text{grid}}$ desde un estado de la grilla $s_i \in \mathcal{S}_i^{\text{grid}}$ es

$$\tilde{s}_i := s_i + \xi_{i,t,m} - a_i, \quad i = 1, 2. \quad (3.9)$$

Balance de masa a nivel de quincena (usado en el despliegue de la política). Al simular la política ya aprendida sobre la trayectoria histórica completa (Sec. Section 3.4), la decisión se toma en cada quincena q , usando el afluente histórico de esa **misma** quincena:

$$V_{i,t,q+1} = V_{i,t,q} + W_{i,t,q} - a_i, \quad q = 0, \dots, 22, \quad (3.10)$$

y, al cerrar el año ($q = 23$), la transición conecta con el primer registro del año siguiente,

$$V_{i,t+1,0} = V_{i,t,23} + W_{i,t+1,0} - a_i. \quad (3.11)$$

En ambos casos a_i es el volumen turbinado decidido para la etapa $m = \mu(q)$ vigente en esa quincena (Sec. Section 3.1.3); a_i no cambia de valor dentro de la misma quincena, pero sí puede cambiar de una quincena a otra dentro de la misma etapa, porque la política se reconsulta con el estado continuo corriente en cada quincena.

Proyección al conjunto factible. En ambos regímenes, el volumen teórico $\tilde{s}_i$ (o $V_{i,t,q+1}$) puede exceder $V_{i,\max}$ o resultar negativo. El volumen físicamente realizable se obtiene proyectando sobre el intervalo factible,

$$s'_i := \text{proj}_{[0, V_{i,\max}]}(\tilde{s}_i) = \min(\max(\tilde{s}_i, 0), V_{i,\max}), \quad (3.12)$$

donde $\text{proj}_{[0, V_{i,\max}]}$ denota al operador que da el punto del intervalo $[0, V_{i,\max}]$ más cercano a $\tilde{s}_i$, y las magnitudes de exceso y faltante se registran como derrame y déficit, respectivamente,

$$\text{derrame}_i := (\tilde{s}_i - V_{i,\max})^+, \quad \text{déficit}_i := (-\tilde{s}_i)^+, \quad (3.13)$$

con $x^+ := \max(x, 0)$.

La etapa evoluciona de manera determinista y cíclica, $m' = (m + 1) \bmod M$, y el estado siguiente es $s' = (s'_1, s'_2, m')$.

Desde la perspectiva de Puterman (1994), la dinámica del MDP se resume en el núcleo de transición $\mathbb{P}(\cdot | s, a)$, que en este modelo **no se especifica en forma analítica cerrada**: toda

la incertidumbre proviene de la afluencia histórica $\xi_{i,t,m}$ (o $W_{i,t,q}$), tratada como una variable aleatoria cuya ley se aproxima por la distribución empírica de las $T = 50$ realizaciones históricas disponibles para cada etapa —no por una tabla de probabilidades de transición sobre estados discretos, puesto que $\mathcal{S}$ es ahora un continuo—.

3.1.5 Función de recompensa ($\mathcal{R}$)

3.1.5.1 Modelo hidráulico-energético linealizado

La energía generada depende del volumen turbinado y de una aproximación lineal de la carga hidráulica. Para cada presa i se define la función de carga **continua**

$$H_i(s_i, s'_i) = H_{i,\max} \cdot \frac{s_i + s'_i}{2 V_{i,\max}}, \quad (3.14)$$

$$H_{1,\max} = 120 \text{ m (Angostura)}, \quad H_{2,\max} = 100 \text{ m (Malpaso)}.$$

Es decir, la carga varía linealmente entre 0 m (presa vacía) y la carga máxima propia de cada presa cuando ésta alcanza su capacidad plena, y se aproxima la carga efectiva durante la etapa/quincena mediante el promedio de la carga al inicio (s_i) y al final (s'_i) del intervalo.

Sea $\eta = 0.9$ la eficiencia de conversión hidráulica-eléctrica y $g = 9.81 \text{ m/s}^2$ la aceleración de la gravedad. La energía generada por la presa i al turbinar a_i (Mm^3) bajo la carga $H_i(s_i, s'_i)$ es

$$E_i(s, a, s') = \frac{\eta g H_i(s_i, s'_i) (a_i \times 10^6)}{3600 \times 10^6} \quad [\text{GWh}], \quad (3.15)$$

donde 10^6 convierte Mm^3 a m^3 y 3600×10^6 convierte julios-equivalentes a GWh (con la densidad del agua $\rho = 1000 \text{ kg/m}^3$ absorbida algebraicamente en la constante 3600). La energía total generada por el sistema en la etapa/quincena es

$$E = E_1 + E_2. \quad (3.16)$$

3.1.5.2 Estructura de penalizaciones

La recompensa incorpora penalizaciones lineales, con coeficientes calibrados para actuar como restricciones blandas de tipo *big-M* (su magnitud domina ampliamente el valor energético del agua, ver ejemplo numérico más abajo). Se definen, por presa i , las siguientes tres penalizaciones:

- **Derrame** (excedente sobre la capacidad máxima):

$$\Pi_i^{\text{derr}} = c_{\text{derr}} \cdot (\tilde{s}_i - V_{i,\max})^+, \quad c_{\text{derr}} := \frac{C_{\text{derr}}}{\Delta}. \quad (3.17)$$

- **Déficit** (faltante respecto de un balance no negativo). *Proporcional a la magnitud del déficit, no una constante fija.*

$$\Pi_i^{\text{def}} = c_{\text{def}} \cdot (-\tilde{s}_i)^+, \quad c_{\text{def}} := \frac{C_{\text{def}}}{\Delta}. \quad (3.18)$$

- **Violación de la curva guía.** *Se penaliza cuando el almacenamiento proyectado **excede** la curva guía (un techo operativo de resguardo).*

$$\Pi_i^{\text{CG}} = c_{\text{CG}} \cdot (s'_i - \text{CG}_i(m))^+, \quad c_{\text{CG}} := \frac{C_{\text{CG}}}{\Delta}. \quad (3.19)$$

con $C_{\text{derr}} = C_{\text{def}} = 10,000$, $C_{\text{CG}} = 5,000$, de modo que $c_{\text{derr}} = c_{\text{def}} \approx 16.67$ y $c_{\text{CG}} \approx 8.33$ por Mm^3 . A modo de referencia de escala: turbinar 1 Mm^3 bajo una carga representativa de 100 m genera, por Equation 3.15, apenas ≈ 0.245 GWh —es decir, c_{derr} es unas 68 veces mayor que el valor energético marginal del mismo volumen, confirmando su papel de penalización dominante y no de costo económico real.

$\text{CG}_i(m)$ es la curva guía de la presa i en la etapa m , definida originalmente en unidades de índice, $\text{CG}_1^{\text{idx}} = (25, 22, 24, 25, 26, 27)$, $\text{CG}_2^{\text{idx}} = (16, 15, 14, 14, 15, 16)$, y convertida a volumen mediante

$$\text{CG}_i(m) := \Delta \cdot \text{CG}_i^{\text{idx}}(m). \quad (3.20)$$

La función de recompensa total, sumada sobre ambas presas, es

$$\mathcal{R}(s, a, s') = \sum_{i=1}^2 \left[E_i - \Pi_i^{\text{derr}} - \Pi_i^{\text{def}} - \Pi_i^{\text{CG}} \right]. \quad (3.21)$$

En el presente trabajo no se modela una distribución analítica explícita de la afluencia; en su lugar se construye un conjunto de aprendizaje empírico, descrito con precisión en la Sec. Section 3.3.1 —y que, como ahí se detalla, **no** consiste en recorrer trayectorias históricas de decisiones reales, sino en evaluar la dinámica y la recompensa sobre una malla exhaustiva de pares estado-acción contra la totalidad de las realizaciones históricas de afluencia. Este enfoque se alinea con un esquema de **Batch Reinforcement Learning** “parcialmente libre de modelo” (Castelletti et al. (2010); Ernst et al. (2005)).

3.2 Ecuación de optimalidad de Bellman

Se adopta la notación Q^* para la función de valor óptima, por ser función del par estado-acción (s, a) —lo que la literatura de aprendizaje por refuerzo llama función de valor-acción— y por consistencia con el nombre de la variable en el código ($\mathbf{Q}$).

Conforme a la teoría clásica de MDPs descontados (Puterman (1994), Teorema 6.2.3), existe una única función de valor-acción óptima Q^* que satisface la ecuación de optimalidad de

Bellman. La razón intuitiva es el factor de descuento $\gamma = 0.95 < 1$: la influencia de una decisión de hoy sobre lo que ocurre dentro de, digamos, 50 etapas está multiplicada por $\gamma^{50} \approx 0.08$, y sigue decayendo geométricamente cuanto más lejos se mire hacia el futuro. Ese decaimiento garantiza que, sin importar con qué aproximación inicial se empiece —incluso $Q^{(0)} \equiv 0$, como hace el algoritmo (Sec. Section 3.3.1 y siguientes)—, al aplicar la ecuación de Bellman una y otra vez las sucesivas aproximaciones se acercan cada vez más entre sí, hasta converger a una única Q^* . Esto es válido tanto si $\mathcal{S}$ es finito (el caso clásico de Puterman) como si tiene una componente continua, como en este modelo (Sec. Section 3.1.2). *(Formalmente, esta propiedad se conoce como que el operador de Bellman es una contracción, y su justificación rigurosa se apoya en el teorema del punto fijo de Banach; no se desarrolla aquí por no ser el objeto central de este capítulo.)*

Dado que la incertidumbre proviene de la afluencia histórica $\xi = (\xi_1, \xi_2)$, cuya ley se aproxima por su distribución empírica $\widehat{P}_m$ sobre las $T = 50$ realizaciones históricas de la etapa m (Sec. Section 3.3.1), la ecuación de optimalidad se escribe como una esperanza sobre dicha distribución empírica —y no como una suma sobre un conjunto discreto de estados siguientes, formalismo que ya no aplica al ser $\mathcal{S}$ un continuo—:

$$Q^*(s, a) = \mathbb{E}_{\xi \sim \widehat{P}_m} \left[\mathcal{R}(s, a, s') + \gamma \max_{a' \in \mathcal{A}_{m'}} Q^*(s', a') \right], \quad s' = f(s, a, \xi), \quad (3.22)$$

con f la función de transición y proyección de las ecuaciones Equation 3.9–Equation 3.12, y $m' = (m + 1) \bmod M$.

Dado que no se dispone de $\widehat{P}_m$ en forma cerrada sino de sus T realizaciones muestrales, el algoritmo de FQI (Sec. siguiente) trabaja con la versión **por muestra** de esta ecuación —el objetivo empírico de Bellman, Equation 3.25—, evaluada sobre cada una de las transiciones del conjunto de aprendizaje, y no con la esperanza poblacional (Equation 3.22) directamente.

3.3 Aproximación numérica mediante Fitted Q-Iteration (FQI)

La Programación Dinámica Estocástica está afectada por la maldición de la dimensionalidad: el costo computacional crece exponencialmente con el número de variables de estado, y requiere además un modelo de transición explícito (Castelletti et al. (2010)). Por ello, el presente trabajo aproxima Q^* mediante Fitted Q-Iteration, un algoritmo de aprendizaje por refuerzo *batch* que ajusta iterativamente un aproximador funcional supervisado a partir de un conjunto de transiciones muestreadas.

3.3.1 Conjunto de aprendizaje “parcialmente libre de modelo”

Concretamente, el conjunto de aprendizaje $\mathcal{F} = \{(x_j, r_j, s'_{1,j}, s'_{2,j}, m'_j)\}_{j=1}^N$ se construye enumerando el producto cartesiano de: la grilla de estado Equation 3.4, la grilla de acción

Equation 3.7, las $M = 6$ etapas, y las $T = 50$ realizaciones históricas de afluencia por etapa Equation 3.8. El vector de características de cada muestra es

$$x_j = (s_{1,j}, s_{2,j}, m_j, a_{1,j}, a_{2,j}) \in \mathcal{S}_1^{\text{grid}} \times \mathcal{S}_2^{\text{grid}} \times \{0, \dots, 5\} \times \mathcal{A}_{m_j}^{\text{grid}} \times \mathcal{A}_{m_j}^{\text{grid}}, \quad (3.23)$$

y, para cada combinación de estado-acción-etapa, se generan $T = 50$ muestras —una por cada año histórico t — aplicando Equation 3.9, Equation 3.12 y Equation 3.21 con la afluencia real Ξ_{i,t,m_j} de ese año. El tamaño total del conjunto de aprendizaje es

$$N = M \times |\mathcal{S}_1^{\text{grid}}| \times |\mathcal{S}_2^{\text{grid}}| \times |\mathcal{A}_1^{\text{grid}}| \times |\mathcal{A}_2^{\text{grid}}| \times T = 6 \times 9 \times 9 \times 9 \times 9 \times 50 = 1,968,300. \quad (3.24)$$

Esta receta de muestreo —barrer exhaustivamente estado y acción sobre una grilla, pero conservar *todas* las realizaciones históricas de la perturbación en cada punto, sin colapsarlas a una tabla de probabilidades ni ajustarles una distribución paramétrica— es la que Castelletti et al. (2010) denominan “**parcialmente libre de modelo**” (*partial model-free*): la dinámica del balance de masa sí se modela analíticamente, pero la ley de la afluencia se deja no paramétrica.

3.3.2 Iteración de Bellman empírica

Se inicializa $Q^{(0)}(s, a) \equiv 0$ para todo (s, a) . Para cada transición $(x_j, r_j, s'_{1,j}, s'_{2,j}, m'_j) \in \mathcal{F}$ del conjunto de aprendizaje, se define el **objetivo de Bellman** de la iteración n por

$$y_j^{(n)} := r_j + \gamma \max_{a' \in \mathcal{A}_{m'_j}} Q^{(n-1)}(s'_{1,j}, s'_{2,j}, m'_j, a'), \quad (3.25)$$

que estima el valor-acción óptimo de x_j combinando la recompensa observada r_j y el mejor valor alcanzable desde el estado siguiente, según la aproximación de la iteración anterior. El cómputo del máximo sobre a' , dado que $(s'_{1,j}, s'_{2,j})$ es en general un punto continuo que no coincide con la grilla Equation 3.4, se describe en la Sec. Section 3.3.3.

3.3.3 Aproximación del operador de maximización sobre estados continuos

******Esta subsección resuelve un punto que el texto anterior dejaba implícito sin justificación: cómo evaluar $\max_{a'} Q^{(n-1)}(s', a')$ cuando s' es continuo. Evaluarlo por fuerza bruta para cada una de las $N \approx 2 \times 10^6$ muestras sería prohibitivo, así que el algoritmo precomputa, para cada etapa m , una superficie de valor máximo sobre la grilla de estado y la interpola:

1. **Evaluación sobre grilla.** Para cada etapa m , se evalúa $Q^{(n-1)}$ en todo el producto $\mathcal{S}_1^{\text{grid}} \times \mathcal{S}_2^{\text{grid}} \times \{m\} \times \mathcal{A}_1^{\text{grid}}(m) \times \mathcal{A}_2^{\text{grid}}(m)$, y se maximiza sobre las dos coordenadas de acción:

$$\widehat{V}^{(n-1)}(s_1^{(p)}, s_2^{(q)}, m) := \max_{a_1, a_2 \in \mathcal{A}_m^{\text{grid}}} Q^{(n-1)}(s_1^{(p)}, s_2^{(q)}, m, a_1, a_2), \quad p, q = 1, \dots, 9, \quad (3.26)$$

obteniéndose una matriz 9×9 por etapa.

2. **Interpolación bilineal.** Sobre esta matriz se construye un interpolador continuo $\tilde{V}^{(n-1)}(\cdot, \cdot; m) : \mathbb{R}^2 \rightarrow \mathbb{R}$ (interpolación multilinear sobre grilla regular), con extrapolación lineal fuera de $[0, V_{1,\max}] \times [0, V_{2,\max}]$.
3. **Sustitución en el objetivo de Bellman.** El máximo de Equation 3.25 se aproxima evaluando el interpolador de la etapa siguiente en el punto continuo genuinamente alcanzado:

$$\max_{a' \in \mathcal{A}_{m'_j}} Q^{(n-1)}(s'_{1,j}, s'_{2,j}, m'_j, a') \approx \tilde{V}^{(n-1)}(s'_{1,j}, s'_{2,j}; m'_j). \quad (3.27)$$

Esta aproximación reduce el costo de $O(N \times |\mathcal{A}^{\text{grid}}|^2)$ evaluaciones del regresor a $O(M \times |\mathcal{S}^{\text{grid}}|^2 \times |\mathcal{A}^{\text{grid}}|^2 + N)$, al reutilizar la misma superficie interpolada para las N/M muestras de cada etapa.

3.3.4 Aproximación funcional por regresión no paramétrica (ExtraTrees)

Una vez calculados los objetivos de Bellman $y^{(n)}$ (Equation 3.25, con el máximo aproximado según Equation 3.27), se ajusta un aproximador $Q^{(n)}$ que minimiza el error cuadrático entre las predicciones $Q^{(n)}(x_j)$ y los objetivos $y_j^{(n)}$ sobre todas las transiciones del conjunto de aprendizaje. Se utiliza, como propone Ernst et al. (2005), un ensamble de *ExtraTrees* (árboles extremadamente aleatorizados), adecuado para aproximar funciones de valor en espacios continuos.

Hiperparámetros (corregidos respecto de la versión previa):

Table 3.2: Hiperparámetros del ensamble de Extra-Trees, según el código, frente a lo reportado en la versión previa del capítulo.

Hiperparámetro	Símbolo	Valor implementado
Número de árboles	M_{tree}	300
Profundidad máxima	—	sin límite (max_depth=None)
Muestras mínimas por hoja	$n_{\min}$	50 (= T)
Variables candidatas por corte	K	$n = 5$ (max_features=1.0)

El valor $n_{\min} = T = 50$ no es arbitrario: al exigir que cada hoja del árbol contenga al menos tantas muestras como años históricos de afluencia, se favorece que cada hoja agrupe una fracción representativa de las T realizaciones de ξ asociadas a un mismo (s, a) aproximado, de modo que el promedio dentro de la hoja aproxime, por la ley (empírica) de los grandes números, la esperanza condicional $\mathbb{E}_{\xi \sim \hat{P}_m}[\cdot]$ que aparece en Equation 3.22. Cada árbol particiona el espacio estado-acción en regiones (hojas) mediante cortes con umbral aleatorio (no exhaustivo, a diferencia de CART/Random Forest) sobre las $K = n = 5$ variables de entrada, y predice, para un punto de consulta, el promedio del objetivo de regresión entre las muestras de entrenamiento

de su misma hoja. La predicción del ensamble es el promedio de las $M_{\text{tree}} = 300$ predicciones individuales.

Nota sobre la Figura de árbol de decisión. La versión previa incluía una figura con la leyenda “Árbol de decisión con profundidad máxima de 14 y un mínimo de 5 muestras por hoja”. Dado que el código real no limita la profundidad (`max_depth=None`) y usa $n_{\min} = 50$, esa leyenda —y, en la práctica, la figura misma, que mostraría un árbol truncado no representativo— debe corregirse o sustituirse por una ilustración esquemática que no afirme una profundidad máxima inexistente.

El algoritmo repite este procedimiento iterativamente.

3.3.5 Criterio de paro basado en desempeño simulado

Un criterio de convergencia del tipo punto-fijo —detener cuando $\|Q^{(n)} - Q^{(n-1)}\|$ cae bajo una tolerancia— **no es aplicable** cuando el aproximador es un ensamble de Extra-Trees: la aleatorización propia de la construcción de cada árbol (elección aleatoria de umbrales de corte) hace que $Q^{(n)}$ y $Q^{(n-1)}$ difieran por ruido de ajuste incluso si ya se hubiese alcanzado, en esencia, la función de valor-acción óptima; esta distancia no converge a cero. Así lo argumentan explícitamente Castelletti et al. (2010), y así lo implementa el código, que en su lugar monitorea el **desempeño operativo simulado** de la política inducida en cada iteración.

Simulación de la política golosa. Cada Δh iteraciones (en el código, $\Delta h = 4$), se simula la operación del sistema bajo la política golosa de $Q^{(n)}$ sobre la trayectoria histórica completa, en resolución de quincena (Sec. Section 3.4), obteniendo energías $e_{t,q}^{(i)}$, derrames $\delta_{t,q}^{(i)}$ y déficits $\epsilon_{t,q}^{(i)}$ por presa.

Funcional de desempeño. Se define

$$\widehat{J}_n := \sum_{t,q} (e_{t,q}^{(1)} + e_{t,q}^{(2)}) - c_{\text{derr}} \sum_{t,q} (\delta_{t,q}^{(1)} + \delta_{t,q}^{(2)}) - c_{\text{def}} \sum_{t,q} (\epsilon_{t,q}^{(1)} + \epsilon_{t,q}^{(2)}), \quad (3.28)$$

una medida de desempeño agregada, **no descontada** y evaluada con afluencias reales quincenales —distinta, por tanto, del objetivo de ajuste Equation 3.25, que opera a nivel de una transición individual y con descuento γ —.

Regla de paro. Se detiene la iteración la primera vez que se observa una caída de $\widehat{J}_n$ respecto del checkpoint inmediatamente anterior (una “reversión”):

$$n^* := \min\{n - \Delta h : \widehat{J}_n < \widehat{J}_{n-\Delta h}\}, \quad (3.29)$$

interpretando la reversión como evidencia de que, a partir de ese punto, predominan las fluctuaciones aleatorias del ajuste sobre el aprendizaje genuino (Castelletti et al. (2010)). Si no se observa ninguna reversión dentro del número máximo de iteraciones permitido, se usa como respaldo el mejor checkpoint observado, $n^* := \arg \max_n \widehat{J}_n$. La aproximación final es

$Q^* := Q^{(n^*)}$, recuperada de una caché de modelos serializados guardada en cada punto de verificación (necesaria porque, por la aleatorización del ensamble, $Q^{(n^*)}$ no podría reproducirse exactamente reentrenando desde cero).

3.4 Política óptima y simulación operativa

Una vez obtenida Q^* , se deriva la política óptima (golosa) $\pi^* : \mathcal{S} \rightarrow \mathcal{A}$,

$$\pi^*(s) := \arg \max_{a \in \mathcal{A}_m^{\text{grid}}} Q^*(s, a), \quad (3.30)$$

donde la maximización se realiza, en la práctica, mediante búsqueda exhaustiva sobre la grilla de acción de la etapa vigente Equation 3.7 (no sobre el conjunto continuo $\mathcal{A}_m$), evaluando Q^* en el estado continuo real —no discretizado— del sistema.

La política se valida mediante simulación en lazo cerrado sobre la serie histórica completa, siguiendo la práctica estándar de validación de políticas de control aprendidas documentada en Bertsekas (2019). El algoritmo, corregido para ser fiel al código, opera así:

1. **Inicialización:** se fijan los volúmenes iniciales $V_{1,0} = 10,000 \text{ Mm}^3$, $V_{2,0} = 6,000 \text{ Mm}^3$ (valores del código; no se especificaban antes).
2. **Mapeo estacional:** para cada quincena q (recorriendo $t = 1, \dots, T$ y, dentro de cada año, $q = 0, \dots, 23$), se determina $m = \mu(q)$ y la grilla de acción $\mathcal{A}_m^{\text{grid}}$ vigente.
3. **Discretización:** $s_i = \mathcal{D}(V_i, N_i)$ — **paso eliminado:** el estado usado para consultar Q^* es el volumen continuo real $(V_{1,t,q}, V_{2,t,q})$, sin redondeo a índice alguno.
4. **Selección de acción,** por búsqueda exhaustiva sobre la grilla de acción de 9×9 combinaciones de la etapa vigente:

$$(a_1^*, a_2^*) = \arg \max_{(a_1, a_2) \in \mathcal{A}_1^{\text{grid}}(m) \times \mathcal{A}_2^{\text{grid}}(m)} Q^*(V_{1,t,q}, V_{2,t,q}, m, a_1, a_2).$$

5. **Balance hídrico,** con el afluente de la **misma** quincena q (corrección respecto de la versión previa, que usaba $q + 1$):

$$V_{i,t,q+1} = V_{i,t,q} + W_{i,t,q} - a_i^*, \quad i = 1, 2.$$

6. **Proyección física,** incluyendo tanto el derrame como el déficit (la versión previa omitía el déficit):

$$V_i^{\text{new}} = \text{proj}_{[0, V_{i,\text{max}}]}(V_{i,t,q+1}), \quad \text{derrame}_i = (V_{i,t,q+1} - V_{i,\text{max}})^+, \quad \text{déficit}_i = (-V_{i,t,q+1})^+.$$

7. **Cálculo energético**, con la carga continua y las cargas máximas distintas por presa (corrección de Equation 3.14):

$$H_i = H_{i,\max} \cdot \frac{V_{i,t,q} + V_i^{\text{new}}}{2 V_{i,\max}}, \quad E_i = \frac{\eta g H_i (a_i^* \times 10^6)}{3600 \times 10^6}.$$

8. **Registro y actualización**: se almacenan energía, derrame, déficit y almacenamiento; el estado se actualiza a V_i^{new} para la siguiente quincena.

3.4.1 Métricas de desempeño y validación estadística

⚠ Cifras pendientes de regenerar

Las tablas siguientes (Table 3.3, Table 3.4) y la conclusión que las acompañaba en la versión previa reportan un derrame total del sistema de $\approx 34,053 \text{ Mm}^3$ y una lectura crítica sobre la mala gestión de la política. Esta cifra **es incompatible con la propia validación documentada en el encabezado del script corregido**, que reporta “0 Mm^3 de derrame y 0 Mm^3 de déficit en ambas presas” al ejecutar exactamente el algoritmo aquí descrito. Es decir, las cifras de la versión previa corresponden, con alta probabilidad, a una ejecución de una versión anterior y no fiel del modelo (la que originó la auditoría documentada en el encabezado de `FQI_corregido.py`), no a la versión actual. No se sustituyen aquí por cifras nuevas para no fabricar resultados: se recomienda **volver a ejecutar el script corregido sobre los datos reales** y regenerar ambas tablas, así como reescribir el párrafo de interpretación en función de los resultados que se obtengan.

Table 3.3: Resumen del desempeño energético del sistema bajo la política óptima aprendida mediante FQI (plantilla; valores por regenerar con `simulacion_FQI_corregida.csv`).

Métrica	Angostura	Malpaso	Sistema Total
Energía promedio quincenal [GWh]	<i>(pendiente)</i>	<i>(pendiente)</i>	<i>(pendiente)</i>
Energía anual estimada [GWh]	<i>(pendiente)</i>	<i>(pendiente)</i>	<i>(pendiente)</i>
Contribución al sistema [%]	<i>(pendiente)</i>	<i>(pendiente)</i>	100.0

Table 3.4: Resumen del desempeño hídrico del sistema bajo la política óptima aprendida mediante FQI (plantilla; valores por regenerar).

Métrica	Angostura	Malpaso	Sistema Total
Derrame total [Mm ³]	<i>(pendiente)</i>	<i>(pendiente)</i>	<i>(pendiente)</i>
Déficit total [Mm ³]	<i>(pendiente)</i>	<i>(pendiente)</i>	<i>(pendiente)</i>

Una vez regeneradas las tablas a partir de una corrida real del script, la interpretación debe contrastar específicamente los totales de derrame y déficit contra la validación reportada en el propio código (0 Mm³ en ambos rubros) antes de emitir un juicio sobre la calidad de la política aprendida; de mantenerse una discrepancia con lo documentado en el script, ésta debería investigarse como posible diferencia entre el entorno de ejecución (datos, semilla aleatoria, versión de librerías) y no asumirse automáticamente como una falla de la política.

3.5 Conclusiones del capítulo

- Síntesis de contribuciones matemáticas y numéricas.
- Reafirmación de la coherencia entre formulación teórica, implementación algorítmica y validación operativa —pendiente de completar una vez regeneradas las métricas de la Sec. Section 3.4.1—.
- Declaración de cierre alineada con los objetivos de la tesis.

4

5

Referencias

- Bertsekas, Dimitri P. 2019. *Reinforcement Learning and Optimal Control*. Athena Scientific.
- Castelletti, A., S. Galelli, M. Restelli, and R. Soncini-Sessa. 2010. “Tree-Based Reinforcement Learning for Optimal Water Reservoir Operation.” *Water Resources Research* 46: W09507. <https://doi.org/10.1029/2009WR008898>.
- Ernst, Damien, Pierre Geurts, and Louis Wehenkel. 2005. “Tree-Based Batch Mode Reinforcement Learning.” *Journal of Machine Learning Research* 6: 503–56. <http://www.jmlr.org/papers/volume6/ernst05a/ernst05a.pdf>.
- IBM. 2025. “¿Qué es el aprendizaje por refuerzo?” IBM. https://www.ibm.com/mx-es/think/topics/reinforcement-learning?mhsrc=ibmsearch_a&mhq=aprendizaje%20por%20refuerzo.
- Puterman, Martin L. 1994. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. Wiley Series in Probability and Statistics. John Wiley & Sons. <https://doi.org/10.1002/9780470316887>.