Fitted Q-Iteration: Estimación de niveles de presas

Erika Rubí Jiménez Guzmán
Asesor: Dr. Yofre Hernán García Gómez

2026-11-11

Tabla de contenidos

Resumen 3

Introduction 4

I Preliminares 5

1 Fundamentos Matemáticos 6
1.1 Inteligencia Artificial (IA) . . . 6
1.1.1 Aprendizaje Automático . . . 6

2 Fundamentos del Sistema Hidroeléctrico 9
2.1 Configuración Hidrológica y Operativa de la Cuenca del Río Grijalva . . . 9
2.2 El Problema de Optimización Operativa Multiobjetivo . . . 10

II Modelo Matemático 11

3 Modelo Matemático de Programación Dinámica Estocástica para Optimizar la Operación de un Sistema Hidroeléctrico 12
3.1 Datos históricos . . . 12
3.2 Formulación Matemática del Proceso de Decisión de Markov . . . 13
3.2.1 Estructura Temporal: quincena y etapas hidrológicas . . . 13
3.2.2 Espacio de Estados y operador de discretización $\mathcal{S}$ . . . 14
3.2.3 Espacio de Acciones . . . 15
3.3 Proceso Estocástico de Afluencias y Distribución Clásica . . . 16
3.3.1 Registro hidroclimático histórico y agregación temporal . . . 16
3.3.2 Discretización y espacio muestral de pares conjuntos . . . 16
3.4 Ecuaciones de Balance Físico y Transición en Cascada . . . 18
3.4.1 Construcción del Núcleo de Transición de Estados Markoviano . . . 20
3.5 Función de Recompensa y Sistema de Penalizaciones Exteriores . . . 20
3.5.1 Modelo Hidráulico-Energético Relativo y Concavidad . . . 20
3.5.2 Restricciones de Curva Guía (POL 7) . . . 21
3.5.3 Penalizaciones exteriores . . . 22
3.5.4 Operador de Esperanza del Beneficio Inmediato (Cálculo de las Funciones Phi) . . . 23

3.6 Ecuación de Optimalidad de Bellman e Inducción hacia Atrás 23
3.6.1 Reglas de decisión y operador de Bellman 23
3.6.2 Algoritmo de inducción hacia atrás cíclico 24
3.7 Convergencia y Semi-norma Span de Puterman 25
3.7.1 Ensamblaje de la Regla de Decisión Óptima: Matriz MEEVS 25
3.8 Simulación Cronológica en Lazo Cerrado y Validación Estadística 26
3.8.1 Algoritmo de Desagregación Temporal y Simulación Forward 26
3.8.2 Modelación Hidráulica Continua y Cálculo de Energía en Gigavatios-Hora 27
3.8.3 Resultados Numéricos, Validación Histórica y Discusión Comparativa . 28
3.9 Conclusiones Metodológicas y Analíticas del Capítulo 30

4 Modelo Matemático Fitted Q-Iteration para Optimizar la Operación de un Sistema Hidroeléctrico. 32
4.1 Formulación como Proceso de Decisión de Markov (MDP) 32
4.1.1 Estructura Temporal (T) 32
4.1.2 Espacio de estados ($\mathcal{S}$) 33
4.1.3 Espacio de acciones ($\mathcal{A}$) 34
4.1.4 Dinámica de transición ($\mathbb{P}$) 35
4.1.5 Función de recompensa ($\mathcal{R}$) 36
4.2 Ecuación de optimalidad de Bellman 38
4.3 Aproximación numérica mediante Fitted Q-Iteration (FQI) 38
4.3.1 Conjunto de aprendizaje "parcialmente libre de modelo" 39
4.3.2 Iteración de Bellman empírica 39
4.3.3 Aproximación del operador de maximización sobre estados continuos . . 40
4.3.4 Aproximación funcional por regresión no paramétrica (ExtraTrees) . . . 40
4.3.5 Criterio de paro basado en desempeño simulado 41
4.4 Política óptima y simulación operativa 42
4.4.1 Métricas de desempeño y validación estadística 43
4.5 Conclusiones del capítulo 44

Referencias 47

Resumen

Aquí pondré un resumen de mi tesis, que se llama “Fitted Q-Iteration: Estimación de niveles de presas”.

Introduction

Esta será la introducción.

ejemplo de una cita Puterman (1994).

Parte I

Preliminares

1 Fundamentos Matemáticos

1.1. Inteligencia Artificial (IA)

La **Inteligencia Artificial (IA)** es un campo de estudio que se centra en la creación de sistemas capaces de realizar tareas que normalmente requieren inteligencia humana. La IA combina diversas disciplinas, incluyendo matemáticas, estadísticas, informática y neurociencia, para desarrollar algoritmos y modelos que permiten a las máquinas aprender, razonar y tomar decisiones de manera autónoma.

Este campo está dividido en varias subáreas, cada una con su enfoque y aplicaciones específicas. Entre las más destacadas se encuentran el **Aprendizaje Automático (Machine Learning)**, **Aprendizaje Profundo (Deep Learning)**, **Procesamiento del Lenguaje Natural**, **Visión por Computadora**, **Robótica**, entre otras. Cada una de estas subáreas utiliza diferentes técnicas y enfoques para abordar problemas complejos y mejorar la capacidad de las máquinas para interactuar con el mundo que las rodea.

1.1.1. Aprendizaje Automático

En este subcampo de la Inteligencia Artificial, las máquinas aprenden a partir de datos, similar a como lo hacemos nosotros, permitiendoles mejorar con la experiencia. El aprendizaje automático se basa en algoritmos que identifican patrones y relaciones en los datos, lo que permite a las máquinas hacer predicciones o tomar decisiones sin ser explícitamente programadas para cada tarea específica. Este enfoque ha revolucionado diversas industrias, desde la medicina hasta la economía, al proporcionar herramientas más eficientes y precisas para el análisis de datos y la toma de decisiones.

El aprendizaje automático se clasifica en tres categorías principales: **Aprendizaje Supervisado**, **Aprendizaje No Supervisado** y **Aprendizaje por Refuerzo**, cada una con sus propias técnicas y aplicaciones. Estas categorías permiten abordar diferentes tipos de problemas y desafíos, desde la clasificación de datos hasta la optimización de estrategias en entornos dinámicos.

Definición 1.1 (Aprendizaje Supervisado)**.** Esta categoría se basa en utilizar conjuntos de datos etiquetados (datos de entrada con sus correspondientes salidas) para entrenar modelos

matemáticos que puedan identificar patrones y a partir de ellos predecir resultados futuros sobre datos nuevos.

Este tipo de aprendizaje es principalmente utilizado en:

- ***Tareas de clasificación:*** los modelos predicen la clase a las que pertenece cada dato. Por ejemplo, identificar si un correo electrónico es spam o no.
- ***Regresión:*** predicen valores numéricos a partir de datos de entrada. Por ejemplo, predecir el precio de una vivienda basado en sus características.

Definición 1.2 (Aprendizaje No Supervisado)**.** A diferencia del aprendizaje supervisado, en este tipo de aprendizaje no se utilizan datos etiquetados. En su lugar, los algoritmos buscan patrones ocultos o agrupaciones dentro de los datos. Estos modelos son utilizados para tareas especificas como:

- ***Agrupamiento (Clustering):*** los modelos identifican grupos de datos similares entre sí. Por ejemplo, segmentar clientes en diferentes grupos según sus comportamientos de compra.
- ***Reducción de dimensionalidad:*** los modelos simplifican los datos manteniendo la mayor cantidad de información posible. Por ejemplo, reducir el número de variables en un conjunto de datos para facilitar su análisis.

Definición 1.3 (Aprendizaje por Refuerzo)**.** En este tipo de aprendizaje automático, los agentes autónomos aprenden a tomar decisiones a partir de la interección con un entorno en el cual reciben recompensas o penalizaciones según sus acciones. A continuación se presentan los conceptos fundamentales de este tipo de aprendizaje

- ***Agente:*** es el decisor, este selecciona las acciones en cada estado.
- ***Entorno:*** descrito como un Markov Decision Process (MDP), el entorno se define como $(\mathcal{S}, \mathcal{A}, \mathbb{P}, \mathcal{R})$, en donde
  - $\mathcal{S}$ es el conjunto de estados,
  - $\mathcal{A}$ es el conjunto de acciones,
  - $\mathbb{P}$ es la función de transición de probabilidad,
  - $\mathcal{R}$ es la función de recompensa.
- ***Estado*** $(\mathcal{S})$: situación actual del agente en el entorno.
- ***Acción*** $(\mathcal{A})$: decisión elegida por agente en el estado $s \in \mathcal{S}$. El conjunto de acciones posibles en un estado se denota como $\mathcal{A}(s)$.
- ***Recompensa*** $(\mathcal{R})$: función que asigna un valor numérico a cada par (s, a), indicando el beneficio o costo de esa acción.

- ***Política*** (π): regla de decisión que especifica cómo el agente selecciona acciones en cada estado. La política puede ser:
    - Determinista $\pi(s) = a$: dado un estado s, el agente selecciona una única acción a.
    - Estocástica $\pi(a|s) = P(A_t = a|S_t = s)$: asigna una probabilidad a cada acción a posible en un estado determinado s.

El aprendizaje por refuerzo se centra esencialmente en la relación entre un agente, entorno y el objetivo (lo que se desea lograr). La literatura formula esta relación en términos de un **Proceso de Decisión de Markov (MDP)**.

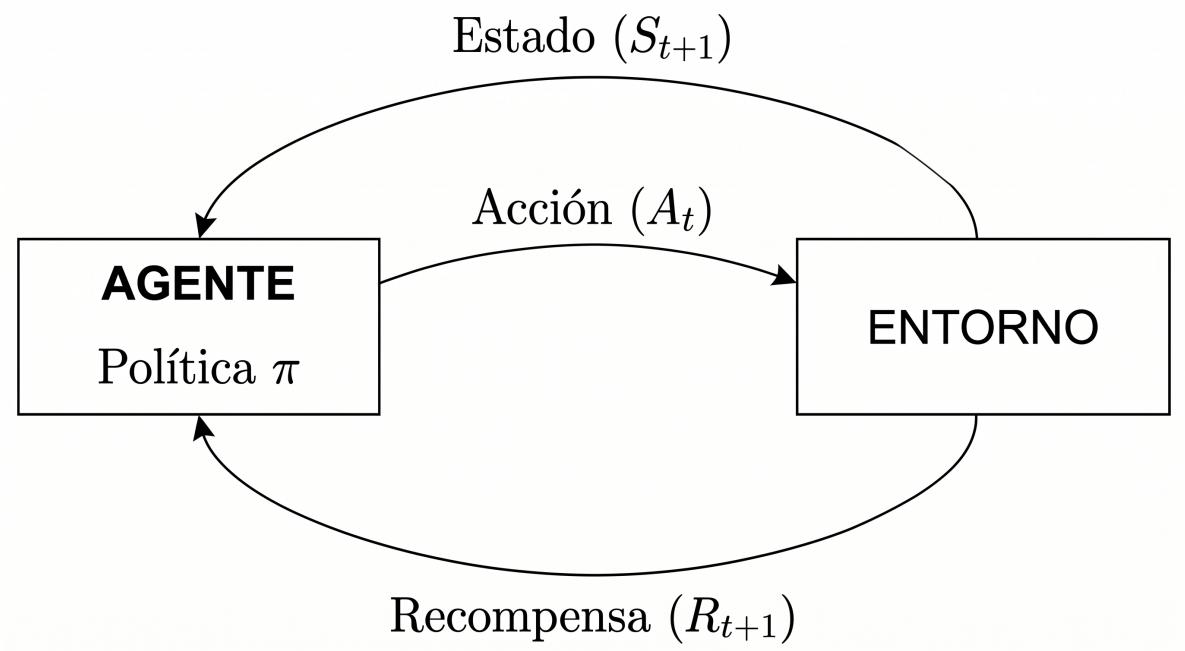


Figura 1.1: Diagrama del proceso de interacción en el aprendizaje por refuerzo.

Véase IBM (2025) para más información sobre estos tipos de aprendizaje y sus aplicaciones.

1.1.1.1. Q-Learning

Existen distintos algoritmos de aprendizaje por refuerzo, entre los cuales se encuentra el **Q-Learning**, este permite a un agente aprender a tomar decisiones en un entorno para maximizar una recompensa acumulada a lo largo del tiempo. Este modelo es model-free, es decir, no requiere un modelo del entorno para aprender, sino que se basa en la experiencia directa del agente a través de la exploración y explotación de su entorno.

2 Fundamentos del Sistema Hidroeléctrico

2.1. Configuración Hidrológica y Operativa de la Cuenca del Río Grijalva

El sistema hidroeléctrico del río Grijalva, localizado en el sureste de México entre los estados de Chiapas y Tabasco, representa la infraestructura hidroenergética más importante del país, aportando una fracción sustancial de la energía hidroeléctrica del Sistema Eléctrico Nacional. El complejo hidrológico comprende cuatro grandes centrales hidroeléctricas dispuestas en serie a lo largo del cauce principal del río: La Angostura (Belisario Domínguez), Chicoasén (Manuel Moreno Torres), Malpaso (Nezahualcóyotl) y Peñitas (Ángel Albino Corzo).

Desde una perspectiva operativa e hidrológica, los cuatro embalses presentan marcadas diferencias estructurales en sus capacidades de almacenamiento útil: - **La Angostura:** Es el embalse de cabecera con la mayor capacidad de almacenamiento del país ($16,200$ hm^3 en su nivel de aguas máximas ordinarias), funcionando como el principal vaso regulador plurianual de la cuenca alta. - **Chicoasén:** Es una central hidroeléctrica de muy alta caída hidráulica con un vaso de regulación pequeña, cuya dinámica operativa consiste fundamentalmente en turbinar el agua descargada por La Angostura, operando a nivel de vaso prácticamente constante. - **Malpaso:** Es el segundo gran embalse del sistema ($9,600$ hm^3 de capacidad máxima), ubicado en la cuenca media. Recibe directamente los volúmenes turbinados y derramados por La Angostura y Chicoasén, más las aportaciones tributarias de su cuenca propia intermedia. - **Peñitas:** Es la obra de toma y regulación terminal de la cascada, con capacidad de almacenamiento reducida, cuya misión primordial es amortiguar las fluctuaciones horarias de turbinado y regular el gasto hacia la planicie de Tabasco.

Conforme a la metodología establecida por Díaz (2010), esta asimetría estructural justifica plenamente modelar la cascada a través de un **sistema equivalente de dos presas mayores con acoplamiento hidráulico en serie**: 1. El subsistema superior, constituido por la presa **La Angostura**, la cual incorpora en su beneficio de generación la carga hidráulica efectiva aportada aguas abajo por la presa **Chicoasén**. 2. El subsistema inferior, integrado por la presa **Malpaso**, que recibe en tránsito los caudales desfogados por el subsistema superior, incorpora las afluencias por cuenca propia intermedia y absorbe en su salto hidráulico el beneficio de la presa **Peñitas**.

2.2. El Problema de Optimización Operativa Multiobjetivo

La gestión operativa del sistema del río Grijalva involucra un conflicto estructural entre dos entidades gubernamentales con objetivos contrapuestos (Díaz (2010)): 1. **Comisión Federal de Electricidad (CFE):** Cuyo mandato rector es maximizar la generación de energía eléctrica limpia y firme, lo que incentiva mantener los embalses en cotas elevadas para maximizar la carga neta disponible en las turbinas hidroeléctricas. 2. **Comisión Nacional del Agua (CONAGUA):** Cuyo mandato institucional es mitigar los riesgos de inundación en las poblaciones ribereñas y centros urbanos de la planicie tabasqueña (especialmente Villahermosa), lo que exige mantener un volumen de resguardo o capacidad de amortiguamiento libre ante crecidas extraordinarias durante la temporada ciclónica.

Para conciliar estos requerimientos, el Comité Técnico de Operación de Obras Hidráulicas (CTOOH) establece una **curva guía** (o curva índice estacional de seguridad), la cual define la trayectoria máxima de almacenamiento admisible a lo largo del año. La optimización de la operación consiste en determinar la regla de extracción de agua de cada vaso que maximice la energía esperada, garantice la confiabilidad de suministro (evitando déficits en estiaje) y minimice estrictamente los vertidos incontrolados y las violaciones a la curva guía.

Definición 2.1 (Fitted Q-Iteration)**.** Algoritmo Offline (aprende analizando el historial de experiencias)…

Parte II

Modelo Matemático

3 Modelo Matemático de Programación Dinámica Estocástica para Optimizar la Operación de un Sistema Hidroeléctrico

En este capítulo se presenta una formulación rigurosa del problema de optimización de la operación de un sistema hidroeléctrico mediante un Proceso de Decisión de Markov (MDP), usando Programación Dinámica Estocástica (PDE) con el fin de obtener la política óptima de operación tomando en cuenta el concepto de curva guía. Se trata de un método exacto: la función de valor se almacena como una tabla indexada por los estados discretizados del sistema y se calcula mediante retropropagación de Bellman (*Backward Induction*).

Lo anterior se propone tal y como lo describe Díaz (2010), quien aplica la PDE para optimizar la operación del sistema hidroeléctrico del río Grijalva. A lo largo del capítulo se enfatiza la conexión precisa entre los elementos matemáticos formales y su correspondiente implementación numérica, analizando las consideraciones metodológicas que permitieron consolidar el modelo y discutiendo los resultados obtenidos de la simulación histórica quincenal.

3.1. Datos históricos

Sea $T = 50$ los años históricos disponibles (periodo 1959–2008), indexados por $t \in \{0, \dots, T-1\}$. Cada uno de ellos subdivididos en 24 quincenas q, con $q \in \{0, \dots, 23\}$ (correspondientes a las columnas de los datos históricos depurados proporcionados por Díaz (2010)).

El sistema físico analizado está compuesto por dos presas principales dispuestas en cascada: La Angostura ($i = 1$), embalse de cabecera con la mayor capacidad de almacenamiento del país, cuya extracción considera adicionalmente la carga hidráulica de la presa Chicoasén. Malpaso ($i = 2$), embalse intermedio que recibe por el cauce del río Grijalva el agua descargada por La Angostura, las aportaciones de su cuenca propia tributaria y la carga de la presa Peñitas.

El volumen de almacenamiento de cada una de ellas en la quincena q del año t se representará por:

$$V_{i,t,q} \in \mathbb{R}^+ \cup \{0\} \quad (\text{Millones de metros cúbicos} - \text{Mm}^3 \text{ o } \text{hm}^3)$$

3.2. Formulación Matemática del Proceso de Decisión de Markov

Conforme a la teoría clásica de control estocástico de Puterman (1994), el problema de optimización hidroeléctrica se formula como un **Proceso de Decisión de Markov con Espacios de Estados y Acciones Discretos**, definido formalmente como la colección de objetos

$$\{(T, \mathcal{S}, \mathcal{A}, \mathbb{P}, \mathcal{R})\},$$

cuyos componentes se describen a continuación.

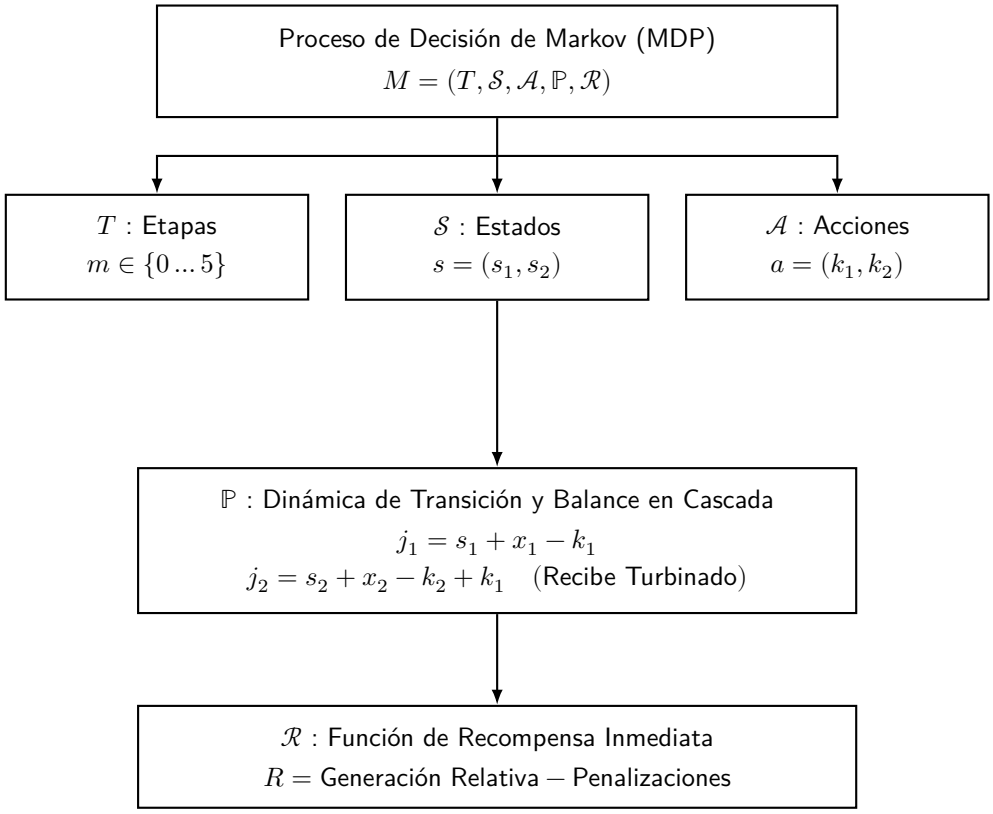


Figura 3.1: Diagrama de componentes del Proceso de Decisión de Markov.

3.2.1. Estructura Temporal: quincena y etapas hidrológicas

Sea $T = 50$ el horizonte temporal de operación subdividido en quincenas operativas q para cada año hidrológico. La fuerte estacionalidad climática de la cuenca del sureste mexicano, caracterizada por un periodo de estiaje prolongado (enero a mayo) seguido por temporadas

de lluvias intensas y actividad ciclónica (junio a diciembre), induce una estructura temporal periódica dentro del ciclo anual (Díaz (2010)).

Para modelar esta periodicidad reduciendo la dimensionalidad computacional sin perder resolución hidrológica, las 24 quincenas se agrupan en $M = 6$ etapas hidrológicas (segmentación temporal del año indexadas por $m \in \{0, 1, 2, 3, 4, 5\}$), mediante la siguiente función de agregación $\mu : \{0, \dots, 23\} \to \{0, \dots, 5\}$ definida por:

$$\mu(q) = \begin{cases} 0, & 0 \le q < 10, \quad \text{(Ene-May, } N_{q,0}\text{=10 quincenas)} \\ 1, & 10 \le q < 14, \quad \text{(Jun-Jul, } N_{q,1}\text{=4 quincenas)} \\ 2, & 14 \le q < 16, \quad \text{(Ago, } N_{q,2}\text{=2 quincenas)} \\ 3, & 16 \le q < 18, \quad \text{(Sep, } N_{q,3}\text{=2 quincenas)} \\ 4, & 18 \le q < 20, \quad \text{(Oct, } N_{q,4}\text{=2 quincenas)} \\ 5, & 20 \le q \le 23, \quad \text{(Nov–Dic, } N_{q,5}\text{=4 quincenas)} \end{cases} \tag{3.1}$$

así, la variable $m = \mu(q)$ representará la etapa hidrológica correspondiente a la quincena q y $N_{q,m}$ denota el número de quincenas contenidas en la etapa m.

3.2.2. Espacio de Estados y operador de discretización $\mathcal{S}$

En cualquier instante temporal, el estado físico de los embalses está determinado por los volúmenes de agua almacenados en La Angostura (V_1) y Malpaso (V_2). Para formular un MDP soluble mediante programación dinámica exacta, el espacio de almacenamiento continuo se discretiza uniformemente utilizando un incremento volumétrico (paso de discretización):

$$\Delta V = 600 \text{ hm}^3 \quad \text{(600 millones de metros cúbicos)}$$

Sea $N_1 = 27$ el número máximo de intervalos discretos para La Angostura y $N_2 = 16$ para Malpaso. Las capacidades físicas máximas de almacenamiento representadas en la rejilla discreta corresponden a:

$$V_{1,\text{máx}} = N_1 \cdot \Delta V = 27 \times 600 \text{ hm}^3 = 16,200 \text{ hm}^3$$

$$V_{2,\text{máx}} = N_2 \cdot \Delta V = 16 \times 600 \text{ hm}^3 = 9,600 \text{ hm}^3$$

Para cualquier volumen físico continuo $V_i \in [0, V_{i,\text{máx}}]$ en la presa $i \in \{1, 2\}$, se define el operador de cuantización (transforma un estado continuo V_i en su estado discreto correspondiente) $\mathcal{D} : \mathbb{R}^+ \to \{0, \dots, N_i\}$ dado por:

$$s_i = \mathcal{D}(V_i) := \text{mín}\left(\text{máx}\left(\left\lfloor \frac{V_i}{\Delta} + \frac{1}{2} \right\rfloor, 0\right), N_i\right)$$

donde $\lfloor \cdot \rfloor$ es la función piso y s_i denota el estado discreto de almacenamiento de la presa i, adoptando la nomenclatura clásica de Puterman (1994).

El espacio de estados conjunto de la cascada para una etapa estacional dada se define como el producto cartesiano de los conjuntos discretos de cada presa:

$$\mathcal{S} = \mathcal{S}_1 \times \mathcal{S}_2 = \{s = (s_1, s_2) \mid s_1 \in \{0, 1, \dots, 27\},\ s_2 \in \{0, 1, \dots, 16\}\}$$

cuya cardinalidad es:

$$|\mathcal{S}| = (N_1 + 1) \times (N_2 + 1) = 28 \times 17 = 476 \text{ estados discretos conjuntos}$$

Al incorporar explícitamente la etapa estacional $m \in \{0, \dots, 5\}$, el estado global del sistema periódico queda completamente descrito por la terna (s_1, s_2, m), lo que suma un total de $476 \times 6 = 2,856$ estados espacio-temporales acoplados.

3.2.3. Espacio de Acciones

Una acción en el sistema representa la decisión simultánea de extracción turbinada en ambos embalses durante la etapa estacional m. Siguiendo la nomenclatura de Díaz (2010) y adaptada al marco de Puterman (1994), la acción se expresa mediante la tupla:

$$a = (k_1, k_2) \in \mathcal{A}$$

donde k_1 y k_2 cuantifican el número de unidades volumétricas discretas de agua turbinadas en La Angostura y Malpaso, respectivamente.

El espacio de acciones admisibles está acotado por las capacidades máximas de turbinado de las obras de toma y cuarto de máquinas instaladas en cada presa:

$$\mathcal{A} = \mathcal{K}_1 \times \mathcal{K}_2 = \{(k_1, k_2) \mid k_1 \in \{0, 1, \dots, K_{1,\text{máx}}\},\ k_2 \in \{0, 1, \dots, K_{2,\text{máx}}\}\}$$

con $K_{1,\text{máx}} = 10$ y $K_{2,\text{máx}} = 10$. El volumen total extraído programado para la etapa completa equivale a:

$$V_{turb,i} = k_i \cdot \Delta V = k_i \times 600 \text{ hm}^3$$

El conjunto de acciones conjuntas posibles consta de:

$$|\mathcal{A}| = (K_{1,\text{máx}} + 1) \times (K_{2,\text{máx}} + 1) = 11 \times 11 = 121$$

decisiones conjuntas por estado. Esta discretización acotada garantiza que los gastos máximos no sobrepasen la capacidad hidroeléctrica instalada ni los límites de flujo seguro aguas abajo, asegurando la factibilidad física de cada trayectoria evaluada en el espacio de decisiones.

3.3. Proceso Estocástico de Afluencias y Distribución Clásica

3.3.1. Registro hidroclimático histórico y agregación temporal

El disturbio estocástico del sistema hidrológico proviene de las afluencias naturales por cuenca propia que ingresan a los embalses en cada etapa. Sea $W_{i,t,q}$ el volumen histórico registrado en la presa i durante la quincena q del año $t \in \{0, \dots, T-1\}$, lo cual produce dos matrices de dimensión 50×24 (una por presa) que constituyen la base de datos empírica del modelo.

Dado que la política de optimización opera a nivel de etapa estacional (y no de quincena individual), el primer paso es agregar la afluencia quincenal a la escala de etapa. Para la etapa estacional m, el volumen acumulado de aportación en el año t es:

$$W_{i,t,m} = \sum_{q:\mu(q)=m} W_{i,t,q}, \quad i \in \{1, 2\} \tag{3.2}$$

El resultado es, para cada etapa m, un par de vectores de longitud T:

$$\mathbf{W}_{1,m} = (W_{1,0,m},\ W_{1,1,m},\ \dots,\ W_{1,T-1,m})^\top \in \mathbb{R}^T$$

$$\mathbf{W}_{2,m} = (W_{2,0,m},\ W_{2,1,m},\ \dots,\ W_{2,T-1,m})^\top \in \mathbb{R}^T$$

que representan la serie histórica de afluencias totales de cada presa durante la etapa m.

3.3.2. Discretización y espacio muestral de pares conjuntos

Para que las afluencias puedan indexar el espacio de probabilidad del MDP, se proyectan los volúmenes continuos $W_{i,t,m}$ a discretos de utilizando el mismo operador de discretización que para el espacio de estados:

$$x_{i,t,m} = \text{máx}\left(0,\ \left\lfloor \frac{W_{i,t,m}}{\Delta V} \right\rfloor\right) \in \mathbb{Z}_{\geq 0} \quad i \in \{1, 2\}$$

Con esta operación se obtiene, para cada etapa m, la **serie histórica de afluencias discretizadas** de cada presa:

$$\mathbf{x}_{i,m} = (x_{i,1,m},\ x_{i,2,m},\ \dots,\ x_{i,N,m})^\top \in \mathbb{Z}_{\geq 0}^T \quad i \in \{1, 2\}$$

A diferencia de un enfoque univariado que modelaría las afluencias de cada presa por separado, el modelo adopta un tratamiento **bivariado conjunto**. Esto preserva la correlación espacial entre las dos cuencas aportantes, que es positiva y estadísticamente significativa dada la escala

de los sistemas meteorológicos que afectan simultáneamente a toda la región del Grijalva. Para cada año t, la afluencia discreta conjunta de la etapa m es el par ordenado:

$$\xi_{t,m} = (x_{1,t,m},\ x_{2,t,m}) \in \mathbb{Z}^2_{\geq 0}$$

La colección de todos los pares observados a lo largo del registro histórico forma la **muestra empírica bivariada**:

$$\{\xi_{0,m},\ \xi_{1,m},\ \cdots,\ \xi_{T-1,m}\}$$

Dentro de esta muestra de $T = 50$ realizaciones pueden existir pares repetidos. Identificando los valores distintos se obtiene el **espacio muestral de pares únicos** de la etapa m:

$$\Omega_m = \{(x_1, x_2) \in \mathbb{Z}^2_{\geq 0} \mid \exists\, t : \xi_{t,m} = (x_1, x_2)\} \quad \text{con cardinalidad} \quad S_m = |\Omega_m|.$$

Probabilidad clásica

Con el espacio muestral Ω_m construido, se aplica la **definición clásica (laplaciana) de probabilidad**: la probabilidad de un evento es el cociente entre el número de casos favorables y el número de casos posibles (igualmente probables). Dado que cada año del registro es un "caso posible" con la misma verosimilitud a priori, y que el número de años en que se observó exactamente el par (x_1, x_2) es el "número de casos favorables", la probabilidad clásica empírica del par $(x_1, x_2) \in \Omega_m$ en la etapa m es:

$$P_m(x_1, x_2) = \frac{n_m(x_1, x_2)}{T} \tag{3.3}$$

donde:

- $T = 50$ es el número total de años de registro (casos posibles, igualmente ponderados),
- $n_m(x_1, x_2) = \{t \in \{0, \ldots, T-1\} : x_{1,t,m} = x_1 \text{ y } x_{2,t,m} = x_2\}$ es la frecuencia absoluta (casos favorables) del par en la etapa m. Esta definición es operacionalmente equivalente a la frecuencia relativa empírica, pero su interpretación es estrictamente laplaciana: se computa el cociente entre el número de años en que el sistema se encontró en ese par de afluencias y el total de años del registro.

La coherencia probabilística de la distribución estimada se verifica comprobando que la suma de todas las probabilidades asignadas a los pares únicos de cada etapa es exactamente la unidad:

$$\sum_{(x_1,x_2)\in\Omega_m} P_m(x_1, x_2) = \sum_{(x_1,x_2)\in\Omega_m} \frac{n_m(x_1, x_2)}{T} = \frac{1}{T} \sum_{(x_1,x_2)\in\Omega_m} n_m(x_1, x_2) = \frac{T}{T} = 1 \quad \forall\, m$$

La última igualdad se cumple porque las frecuencias absolutas de todos los pares únicos de la etapa m suman exactamente T (cada año contribuye a exactamente un par de la etapa).

Este resultado se verifica numéricamente para las seis etapas antes de iniciar el algoritmo de optimización, garantizando que la distribución satisface los axiomas de Kolmogorov.

La siguiente tabla reporta el número de pares únicos S_m identificados en cada etapa tras procesar los 50 años del registro:

Tabla 3.1: Cardinalidad del espacio muestral de afluencias conjuntas por etapa

Etapa m	Período	$N_{q,m}$	$S_m = \lvert\Omega_m\rvert$	Régimen hidrológico
0	Ene–May	10	8	Estiaje (baja variabilidad)
1	Jun–Jul	4	16	Inicio de lluvias
2	Ago	2	13	Lluvias plenas
3	Sep	2	21	Pico de avenidas
4	Oct	2	26	Recesión de avenidas (alta variabilidad)
5	Nov–Dic	4	21	Transición a estiaje

La etapa 0 presenta la menor diversidad de pares ($S_0 = 8$), consistente con el comportamiento hidrológico predecible y de baja varianza del estiaje prolongado. Las etapas de mayor actividad convectiva y ciclónica (3 y 4) alcanzan los valores más altos de S_m (21 y 26), lo que refleja la alta irregularidad interanual de los escurrimientos durante los meses de máximas avenidas. La cardinalidad máxima posible es $T = 50$ pares únicos (un par distinto por año); en ninguna etapa se alcanza este límite, lo que indica la presencia de realizaciones repetidas que concentran la masa de probabilidad en los escenarios hidrológicos más frecuentes.

3.4. Ecuaciones de Balance Físico y Transición en Cascada

La evolución del sistema está gobernada por la ley física de conservación de masa hidrológica. En un sistema de presas en cascada, la interacción hidrodinámica impone un **acoplamiento unidireccional en serie**: todo el volumen descargado por el embalse superior (La Angostura) ingresa directamente al embalse inferior (Malpaso).

Dado el estado inicial $s = (s_1, s_2)$, una decisión de extracción conjunta $a = (k_1, k_2)$ y una realización estocástica de afluencias $X_m = (x_1, x_2) \in \Omega_m$, las ecuaciones de balance de masa en unidades discretas son:

1. Balance en el Embalse Superior (La Angostura): El balance hidráulico potencial al cierre de la etapa es:

$$v_1 = s_1 + x_1 - k_1$$

Debido a que el volumen físico de almacenamiento está acotado por la capacidad máxima N_1 y el fondo muerto (0), se presentan dos condiciones de frontera física:

- **Derrame volumétrico ($derr_1$):** Si el balance potencial excede la capacidad máxima de la presa ($v_1 > N_1$), el excedente se derrama por vertedor:

$$derr_1 = \text{máx}(0,\, v_1 - N_1)$$

- **Déficit de extracción (def_1):** Si la extracción decidida supera el agua disponible en la presa ($v_1 < 0$), se incurre en una insatisfacción de la meta de extracción:

$$def_1 = \text{máx}(0,\, -v_1)$$

El estado discreto final efectivo s_1' de La Angostura queda proyectado dentro del intervalo admisible:

$$s_1' = \text{mín}\left(N_1,\, \text{máx}(0,\, v_1)\right) \tag{3.4}$$

2. Balance en Cascada en el Embalse Inferior (Malpaso): El embalse de Malpaso recibe sus aportaciones naturales por cuenca propia x_2, efectúa su extracción k_2 y recibe la descarga turbinada de La Angostura (k_1), la continuidad física en cascada establece:

$$v_2 = s_2 + x_2 - k_2 + k_1$$

De forma análoga, se cuantifican el derrame y el déficit en Malpaso mediante:

$$derr_2 = \text{máx}(0,\, v_2 - N_2)$$

$$def_2 = \text{máx}(0,\, -v_2)$$

El estado discreto final efectivo s_2' se obtiene como:

$$s_2' = \text{mín}\left(N_2,\, \text{máx}(0,\, v_2)\right) \tag{3.5}$$

Este acoplamiento en serie asegura que el volumen turbinado en la presa alta sea aprovechado en la presa baja para generación hidroeléctrica, reflejando fielmente la física de la cascada del río Grijalva. La aplicación conjunta de las Ecuación 3.4 y Ecuación 3.5 permite definir la función de transición determinista $f_m(s, a, x)$ que mapea el estado actual, la acción y la realización de afluencias al estado sucesor:

$$s' = (s_1', s_2') = f_m(s,\, a,\, x). \tag{3.6}$$

3.4.1. Construcción del Núcleo de Transición de Estados Markoviano

De acuerdo con Puterman (1994), la probabilidad condicional de que el sistema transite al estado $s' \in S$ al aplicar la acción $a \in A$ sobre el estado $s \in S$ en la etapa m se define formalmente mediante el núcleo estocástico:

$$p_m(s' \mid s, a) = \sum_{(x_1,x_2)\in\Omega_m} P_m(x_1, x_2) \cdot \mathbf{1}[f_m(s, a, (x_1, x_2)) = s'] \tag{3.7}$$

donde $\mathbf{1}[\cdot]$ es la función indicadora. Este núcleo de transición satisface la **propiedad de Markov**: dada la acción a y el estado actual s, la distribución de probabilidad del estado sucesor s' es independiente de todos los estados y acciones anteriores a s. Esta propiedad es fundamental para la validez del principio de optimalidad de Bellman, que se desarrolla en la Sección 3.6 (Puterman (1994)).

Por construcción, para cada par (s, a) y cada etapa m, este operador satisface los axiomas fundacionales de Puterman:

$$p_m(s' \mid s, a) \geq 0 \quad \forall\, s' \in S, \qquad \sum_{s'\in S} p_m(s' \mid s, a) = 1 \tag{3.8}$$

Asimismo, en virtud de que el escurrimiento aleatorio X_m se modela como independiente del historial previo condicionada la etapa estacional m, el proceso satisface rigurosamente la **propiedad de Markov**:

$$\mathbb{P}\left(X_{t+1} = s' \;\middle|\; X_1 = s^{(1)}, Y_1 = a^{(1)}, \ldots, X_t = s, Y_t = a\right) = p_m(s' \mid s, a) \tag{3.9}$$

donde X_t e Y_t denotan las variables aleatorias que representan el estado y la acción en la época t, respectivamente.

3.5. Función de Recompensa y Sistema de Penalizaciones Exteriores

3.5.1. Modelo Hidráulico-Energético Relativo y Concavidad

La generación de energía en un embalse hidroeléctrico depende del caudal turbinado y de la carga hidráulica neta disponible, que a su vez es función del nivel del embalse y, por ende, de su volumen almacenado. Para representar esta relación de forma compatible con la estructura discreta del MDP, se introduce la métrica de **generación hidroeléctrica relativa**. En primer lugar, se define el **turbinado efectivo** de la presa i, que descuenta el déficit de almacenamiento que impide turbinar el volumen planificado:

$$turb_1 = \text{máx}(0,\, k_1 - def_1)$$

$$turb_2 = \text{máx}(0,\, k_2 - def_2)$$

Conforme a la formulación teórica de Díaz (2010), la potencia hidroeléctrica instantánea es proporcional al producto del caudal turbinado por la caída hidráulica neta disponible. En la formulación discreta de la PDE, la carga hidráulica efectiva media durante la etapa estacional se modela en función del almacenamiento promedio entre el inicio y el final de la etapa:

$$\bar{s}_i = \frac{s_i + s_i'}{2}, \quad i \in \{1, 2\}.$$

La generación relativa se define entonces como el producto del turbinado efectivo y el almacenamiento medio:

$$ge_1(s_1, k_1, x_1) = turb_1 \cdot \left(\frac{s_1 + s_1'}{2}\right)$$

$$ge_2(s_2, k_2, x_2, k_1) = turb_2 \cdot \left(\frac{s_2 + s_2'}{2}\right)$$

$$GE_{rel}(s, a, X_m) = ge_1 + ge_2$$

Esta formulación posee una propiedad matemática crucial demostrada en la teoría de optimización convexa Bertsekas (2019), la función de generación relativa induce **concavidad estricta** respecto a las variables de decisión k_i. En efecto, sustituyendo el balance de masa sin déficit ($s_i' = s_i + x_i - k_i$), la derivada de segundo orden respecto a la extracción es estrictamente negativa:

$$\frac{\partial^2 ge_i}{\partial k_i^2} = -1 < 0$$

Esta concavidad asegura que el problema de maximización posea rendimientos marginales decrecientes respecto a la extracción, evitando comportamientos oscilatorios y garantizando una convergencia monótona y numéricamente estable en el algoritmo de Bellman.

3.5.2. Restricciones de Curva Guía (POL 7)

La Curva Guía POL 7 representa el instrumento normativo que establece los niveles máximos de almacenamiento seguro para cada embalse y cada etapa del año hidrológico. Esta restricción surge del conflicto operativo entre la Comisión Federal de Electricidad (CFE), que tiene incentivos para mantener los embalses lo más llenos posible con el fin de maximizar la generación, y la Comisión Nacional del Agua (CONAGUA), que exige niveles de almacenamiento suficientemente bajos para garantizar la capacidad de control de avenidas durante la temporada de lluvias. Los niveles máximos de almacenamiento seguro $\bar{s}_i(m)$, expresados en unidades discretas, se muestran en la siguiente tabla:

Tabla 3.2: Niveles máximos de almacenamiento seguro según Curva Guía POL 7

Etapa m	$\bar{s}_1(m)$ (La Angostura)	Vol. equiv. (hm^3)	$\bar{s}_2(m)$ (Malpaso)	Vol. equiv. (hm^3)
0	27	16,200	16	9,600
1	27	16,200	16	9,600
2	26	15,600	16	9,600
3	24	14,400	16	9,600
4	22	13,200	16	9,600
5	20	12,000	15	9,000

El rebase de la Curva Guía en la presa i durante la etapa m se cuantifica como:

$$\text{rebaseCG}_i = \text{máx}(0,\ s'_i - \bar{s}_i(m))$$

La incorporación explícita de esta restricción en la función de recompensa, mediante una penalización proporcional al rebase, permite que el algoritmo aprenda a respetar la Curva Guía como parte de la política óptima, sin necesidad de imponer restricciones duras que complicarían la estructura del problema de optimización.

3.5.3. Penalizaciones exteriores

Para incorporar los objetivos de seguridad hidrológica y evitar que las decisiones óptimas violen los límites operativos seguros, el modelo adopta el **método de funciones de penalización exterior**. Se definen tres penalizaciones no lineales:

1. Penalización por Derrame: El agua que se vierte por vertedor no genera energía eléctrica y representa un riesgo potencial de inundación aguas abajo:

$$\Pi_{derr} = C_{derr} \cdot (derr_1 + derr_2), \quad C_{derr} = 10,000$$

2. Penalización por Déficit Hídrico: La incapacidad de satisfacer las demandas de extracción compromete la confiabilidad energética y el abastecimiento de agua:

$$\Pi_{def} = C_{def} \cdot (def_1 + def_2), \quad C_{def} = 10,000$$

3. Penalización por Violación de Curva Guía (POL 7): Para preservar la capacidad de regulación ante avenidas hidrológicas extremas, la CONAGUA fijan los niveles máximos de almacenamiento seguro estacional. Cualquier almacenamiento final s'_i que supere dicho umbral es fuertemente castigado:

$$\text{rebaseCG}_1 = \text{máx}(0,\ s'_1 - \bar{s}_1(m))$$

$$\text{rebaseCG}_2 = \max\left(0,\ s_2' - \bar{s}_2(m)\right)$$

$$\Pi_{CG} = C_{CG} \cdot (\text{rebaseCG}_1 + \text{rebaseCG}_2), \quad C_{CG} = 5,000$$

Los valores numéricos de la Curva Guía POL 7 en estados discretos por etapa estacional se detallan en la siguiente tabla:

La función de beneficio inmediato determinista $b_m(s, a, X_m)$ ante una realización estocástica $X_m = (x_1, x_2)$ queda formalizada como:

$$b_m(s, a, x) = (ge_1 + ge_2) - \Pi_{derr} - \Pi_{def} - \Pi_{CG}$$

La magnitud de los coeficientes ($C_{derr} = 10^4$, $C_{def} = 10^4$, $C_{CG} = 5 \times 10^3$) es órdenes de magnitud superior a la generación relativa máxima ($\sim 10^2$), lo que convierte a estas penalizaciones en barreras casi-exactas que fuerzan a la política óptima a permanecer dentro del dominio físicamente admisible.

3.5.4. Operador de Esperanza del Beneficio Inmediato (Cálculo de las Funciones Phi)

Conforme a la Ecuación (2.1.1) de Puterman (1994) (Capítulo 2, Sección 2.1.3), la recompensa inmediata esperada $r_m(s, a)$ se obtiene integrando la función de beneficio sobre la distribución de transición estocástica:

$$r_m(s, a) = \mathbb{E}_{X_m}[b_m(s, a, X_m)] = \sum_{(x_1, x_2) \in \Omega_m} P_m(x_1, x_2) \cdot b_m(s, a, (x_1, x_2)) \tag{3.10}$$

Este tensor tridimensional, indexado por etapa m, estado s y acción a, se precalcula antes de iniciar el algoritmo de inducción hacia atrás. La precalculación es computacionalmente conveniente porque la esperanza del beneficio es independiente de la iteración del algoritmo: su valor depende únicamente de los parámetros del modelo, que son fijos. De este modo, el costo computacional de evaluar $r_m(s, a)$ se incurre una sola vez, y las iteraciones del algoritmo de Bellman se reducen a operaciones de comparación sobre la función de valor, con acceso constante a la tabla precalculada de beneficios esperados.

3.6. Ecuación de Optimalidad de Bellman e Inducción hacia Atrás

3.6.1. Reglas de decisión y operador de Bellman

Una **regla de decisión determinista markoviana** para la etapa m es una función $\pi_m : S \to A$ que prescribe una acción de extracción $a = \pi_m(s)$ para cada estado $s \in S$. Una política determinista estacionaria por etapas se define como la secuencia $\pi = \{\pi_0, \ldots, \pi_5\}$, que consiste

en la aplicación sucesiva de las reglas de decisión π_m. El objetivo del agente de optimización es encontrar la política óptima $\pi^* = \{\pi_0^*, \dots, \pi_5^*\}$ que maximiza el beneficio total acumulado a lo largo del horizonte de planificación.

Siguiendo la Definición 6.2.1 y la Ecuación (6.2.2) de Puterman (1994), adaptadas al caso sin descuento temporal ($\lambda = 1$), se define el **operador de optimalidad de Bellman** para la etapa m, denotado $L_m : \mathbb{R}^{|S|} \to \mathbb{R}^{|S|}$, como:

$$(L_m\, v)(s) = \max_{a \in A} \left\{ \Phi_m(s,a) + \sum_{s' \in S} p_m(s' \mid s, a)\, v(s') \right\} \quad \forall\, s \in S \tag{3.11}$$

Sustituyendo el núcleo estocástico (Ecuación 3.7), el operador de Bellman se reescribe operativamente sobre el espacio muestral de afluencias como:

$$(L_m\, v)(s) = \max_{a \in A} \left\{ \Phi_m(s,a) + \sum_{(x_1,x_2) \in \Omega_m} P_m(x_1,x_2) \cdot v\Big(f_m(s,a,(x_1,x_2))\Big) \right\} \tag{3.12}$$

donde $\Phi_m(s,a)$ es el beneficio inmediato esperado definido en la Sección 3.5.4 y f_m es la función de transición en cascada de la Sección 3.4. El operador L_m es monótono (conserva el orden parcial entre funciones de valor) y, para $\lambda < 1$, es una contracción en norma infinito.

La acción que maximiza el término entre llaves en la Ecuación (Ecuación 3.12) define la regla de decisión codiciosa (*greedy*) asociada a la función de valor v:

$$\pi_m^v(s) \in \arg\max_{a \in A} \left\{ \Phi_m(s,a) + \sum_{(x_1,x_2) \in \Omega_m} P_m(x_1,x_2) \cdot v\Big(f_m(s,a,(x_1,x_2))\Big) \right\}. \tag{3.13}$$

3.6.2. Algoritmo de inducción hacia atrás cíclico

Dentro de un ciclo anual determinado $c \in \{1, 2, ...\}$, el principio de optimalidad de Bellman (Puterman 1994, Algoritmo 4.3.1) se aplica en sentido cronológico inverso, retrocediendo desde la etapa 5 hasta la etapa 0:

$$u_m^{(c)}(s) = (L_m\, u_{m+1}^{(c)})(s) \quad \text{para } m = 5,\ 4,\ 3,\ 2,\ 1,\ 0. \tag{3.14}$$

El enlace inter-anual fundamental que conecta los ciclos de planificación consecutivos establece que la función de valor terminal de la etapa 6 en el ciclo c corresponde a la función de valor calculada al inicio del año previo (Díaz 2010):

$$u_{M+1}^{(c)}(s) \equiv v^{(c-1)}(s) \quad \forall\, s \in S \tag{3.15}$$

con condición inicial nula $v^{(0)}(s) = 0$ para todo $s \in S$. Por tanto, el resultado de una barrida anual completa que integra las seis etapas queda encapsulado por el **operador anual compuesto**:

$$L = L_1 \circ L_2 \circ L_3 \circ L_4 \circ L_5 \circ L_6 : \mathbb{R}^{|S|} \to \mathbb{R}^{|S|} \tag{3.16}$$

La sucesión de funciones de valor anuales $\{v^{(c)}\}_{c\geq 1}$ generada por el algoritmo de iteración de valor (*Value Iteration*) satisface:

$$v^{(c)} = L(v^{(c-1)}) = L^c(v^{(0)}) \quad \forall\, c = 1, 2, 3, \ldots \tag{3.17}$$

3.7. Convergencia y Semi-norma Span de Puterman

En problemas de optimización con horizonte infinito y sin descuento ($\lambda = 1$), los beneficios se acumulan ilimitadamente en cada ciclo anual. Conforme a la teoría general de procesos unichain de Puterman (1994) (Capítulo 8, Sección 8.4; Sección 8.5), cuando el proceso posee una única clase recurrente bajo la política óptima, los iterados de valor admiten la **descomposición de Laurent de ganancia y sesgo** [Teorema 8.5.1]:

$$v^{(c)}(s) = c \cdot g^* + h^*(s) + \varepsilon^{(c)}(s) \quad \forall\, s \in S \tag{3.18}$$

donde:

- $g^* \in \mathbb{R}$ es la **ganancia media anual óptima** (*optimal average reward* o *gain*), un escalar estrictamente idéntico para todos los estados $s \in S$ [Puterman 1994, Teorema 8.4.1, p. 344].
- $h^*(s) \in \mathbb{R}$ es la **función de sesgo** (*bias function*), que expresa el valor diferencial o ventaja relativa de iniciar el año en el estado s en comparación con un estado neutro de referencia.
- $\varepsilon^{(c)}(s)$ es un término transitorio de aproximación que satisface $\lim_{c\to\infty} \|\varepsilon^{(c)}\|_\infty = 0$.

3.7.1. Ensamblaje de la Regla de Decisión Óptima: Matriz MEEVS

Para posibilitar la instrumentación operativa en los centros de despacho y salas de control de la CFE y el Centro Nacional de Control de Energía (CENACE), la política de extracción óptima obtenida se compacta en la **Matriz de Extracciones de Embalses en Vasos del Sistema (MEEVS)** (Díaz 2010).

Para cada una de las 6 etapas estacionales, la matriz MEEVS se estructura como una retícula bidimensional de tamaño 28×17 (28 estados de La Angostura $\times$ 17 estados de Malpaso), en la cual cada elemento contiene un código entero posicional de cuatro dígitos en formato `AAMM`:

$$\text{MEEVS}_m(i_1, i_2) = 100 \cdot k_1^*(i_1, i_2, m) + k_2^*(i_1, i_2, m)$$

donde:

- `AA` (centenas y millares): Unidades discretas de turbinado óptimo asignadas a La Angostura ($k_1^* \in [0, 10]$).
- `MM` (decenas y unidades): Unidades discretas de turbinado óptimo asignadas a Malpaso ($k_2^* \in [0, 10]$).

A continuación se muestra un extracto representativo de la matriz MEEVS calculada para la Etapa 1 (Enero–Mayo) en la zona de almacenamientos medios y altos:

Tabla 3.3: Extracto de la Matriz MEEVS para la Etapa 1 (Enero–Mayo) en niveles de almacenamiento medio y alto.

Angostura (i_1) \ Malpaso (i_2)	$i_2 = 10$	$i_2 = 11$	$i_2 = 12$	$i_2 = 13$	$i_2 = 14$	$i_2 = 15$	$i_2 = 16$
$i_1 = 20$	0300	0200	0100	0101	0102	0204	0205
$i_1 = 21$	0400	0300	0200	0201	0202	0305	0306
$i_1 = 22$	0500	0400	0300	0301	0302	0406	0407
$i_1 = 23$	0500	0400	0401	0402	0404	0507	0508
$i_1 = 24$	0500	0400	0502	0503	0505	0608	0609
$i_1 = 25$	0500	0501	0603	0604	0606	0709	0710
$i_1 = 26$	0601	0602	0704	0705	0707	0810	0710
$i_1 = 27$ **(Lleno)**	0702	0703	0805	0806	0808	0810	**0710**

La estructura de la matriz exhibe una coordinación hidráulica físicamente coherente: - Cuando Malpaso se encuentra en niveles de almacenamiento moderados ($i_2 \leq 12$), La Angostura incrementa su turbinado ($k_1^* \in [3, 7]$) para transferir agua con alta carga hidráulica, mientras Malpaso retiene volumen ($k_2^* = 0$) para elevar su propio almacenamiento hacia cotas eficientes. - Cuando Malpaso se acerca a su capacidad máxima ($i_2 = 15, 16$), Malpaso abre su turbinado al límite admisible ($k_2^* = 10$) y La Angostura regula su extracción ($k_1^* = 7$, código `0710`), coordinando la cascada para desalojar el agua de manera controlada sin provocar derrames en los vertedores ni rebasar los límites de seguridad.

3.8. Simulación Cronológica en Lazo Cerrado y Validación Estadística

3.8.1. Algoritmo de Desagregación Temporal y Simulación Forward

Siguiendo las mejores prácticas de validación de políticas en recursos hídricos (**?**; Castelletti et al. 2010), la política óptima π^* derivada de la PDE se evalúa mediante una simulación cronológica forward en lazo cerrado sobre la serie histórica de escurrimientos quincenales (1959–2008, 1,200 quincenas). Este procedimiento confronta la política discreta con la continuidad hidrológica real a paso quincenal.

Para cada quincena consecutiva $q \in \{1, \ldots, 1200\}$: 1. **Identificación de la Etapa Estacional:** Se determina la etapa correspondiente $m = \mu(q)$ y su duración en quincenas $N_{q,m}$. 2. **Observación y Discretización del Estado:** A partir de los volúmenes continuos disponibles $V_{1,q}$ y $V_{2,q}$, se obtienen los estados discretos $i_1 = \mathcal{Q}_1(V_{1,q})$ e $i_2 = \mathcal{Q}_2(V_{2,q})$. 3. **Consulta de la Matriz MEEVS:** Se lee la acción óptima conjunta (k_1^*, k_2^*) correspondiente en tiempo de acceso constante $\mathcal{O}(1)$. 4. **Desagregación Volumétrica Quincenal:** La cuota de extracción decidida para la etapa se desagiega uniformemente a nivel quincenal:

$$Q_{des,l} = \frac{k_l^* \cdot \Delta V}{N_{q,m}}, \quad l \in \{1, 2\}$$

5. **Balance Hidráulico Continuo Acoplado:** - Para La Angostura:

$$V_{1,bal} = V_{1,q} + W_{1,q} - Q_{des,1}$$

$$Derr_{1,q} = \text{máx}(0,\, V_{1,bal} - V_{1,\text{máx}}), \qquad Def_{1,q} = \text{máx}(0,\, -V_{1,bal})$$

$$Turb_{1,q} = \text{máx}(0,\, Q_{des,1} - Def_{1,q})$$

$$V_{1,q+1} = \text{mín}\left(V_{1,\text{máx}},\, \text{máx}(0,\, V_{1,bal})\right)$$

- Para Malpaso (recibe la descarga total de La Angostura, constituida por turbinado y derrame):

$$Descarga_{1,q} = Turb_{1,q} + Derr_{1,q}$$

$$V_{2,bal} = V_{2,q} + W_{2,q} + Descarga_{1,q} - Q_{des,2}$$

$$Derr_{2,q} = \text{máx}(0,\, V_{2,bal} - V_{2,\text{máx}}), \qquad Def_{2,q} = \text{máx}(0,\, -V_{2,bal})$$

$$Turb_{2,q} = \text{máx}(0,\, Q_{des,2} - Def_{2,q})$$

$$V_{2,q+1} = \text{mín}\left(V_{2,\text{máx}},\, \text{máx}(0,\, V_{2,bal})\right)$$

3.8.2. Modelación Hidráulica Continua y Cálculo de Energía en Gigavatios-Hora

A diferencia del modelo de optimización (que utiliza almacenamiento medio y carga relativa), la fase de simulación forward calcula la energía hidroeléctrica real en unidades físicas (Gigavatios-hora, GWh) integrando las curvas polinomiales reales de elevación-almacenamiento de la Comisión Federal de Electricidad (**?**):

$$Z_1(V) = 0.0214 \cdot V^{0.7763} + 500.0 \text{ [msnm]}$$
$$Z_2(V) = 0.0100 \cdot V^{0.8982} + 144.0 \text{ [msnm]}$$

La elevación media durante la quincena se calcula mediante la semisuma:

$$\bar{Z}_l = \frac{Z_l(V_{l,q}) + Z_l(V_{l,q+1})}{2}, \quad l \in \{1, 2\}$$

Las cargas hidráulicas netas efectivas $H_{net,l}$ consideran las cotas de desfogue y el aprovechamiento de los saltos adicionales proporcionados por las presas Chicoasén y Peñitas: - **La Angostura:** La carga neta toma como nivel de restitución la cota de desfogue de 392.5 msnm e incorpora la carga hidráulica de Chicoasén (170.0 m):

$$H_{net,1} = \text{máx}\left((\bar{Z}_1 - 392.5) + 170.0,\ 100.0\right) \text{ [m]}$$

- **Malpaso:** La carga neta toma el nivel de restitución de 87.5 msnm e incorpora la carga de Peñitas (40.0 m):

$$H_{net,2} = \text{máx}\left((\bar{Z}_2 - 87.5) + 40.0,\ 50.0\right) \text{ [m]}$$

La energía hidroeléctrica generada en la quincena se deduce a partir de la primera ley de la termodinámica para turbinas hidráulicas:

$$E_l \text{ [GWh]} = \frac{\rho \cdot g \cdot \eta \cdot H_{net,l} \cdot (Turb_{l,q} \times 10^6)}{3600 \times 10^6} = \left(\frac{9.81 \cdot \eta}{3600}\right) \cdot H_{net,l} \cdot Turb_{l,q}$$

donde $\rho = 1000$ kg/m^3 es la densidad del agua, $g = 9.81$ m/s^2 es la aceleración gravitacional y $\eta = 0.88$ es la eficiencia global del conjunto turbina-generador. El factor de conversión constante resulta:

$$\mathcal{C}_{GWh} = \frac{9.81 \times 0.88}{3600} \approx 2.398067 \times 10^{-3} \frac{\text{GWh}}{\text{m} \cdot \text{hm}^3}$$

3.8.3. Resultados Numéricos, Validación Histórica y Discusión Comparativa

A partir de la ejecución del algoritmo de simulación forward quincenal implementado en `simulacion_pde_unificada_claude.py` sobre las 1,200 quincenas históricas, se obtienen las estadísticas de desempeño operativo del sistema.

En la siguiente tabla se resumen las métricas hidroenergéticas consolidadas:

Tabla 3.4: Desempeño hidroeléctrico de la política óptima MEEVS (Curva Guía POL 7) en el periodo 1959–2008.

Métrica de Desempeño	La Angostura	Malpaso	Sistema Total
Energía promedio quincenal [GWh/q]	337.00	242.16	**579.16**
Energía media anual estimada [GWh/año]	8,088.00	5,811.84	**13,899.90**
Energía total acumulada (50 años) [GWh]	404,400.12	290,594.91	**694,995.03**
Contribución energética porcentual [%]	58.2	41.8	**100.0**
Caudal medio turbinado [m^3/s]	364.81	593.17	—
Turbinado medio quincenal [hm^3/q]	472.80	768.75	1,241.55

En la siguiente tabla se presentan los indicadores de seguridad hidrológica, control de avenidas y confiabilidad:

Tabla 3.5: Desempeño hidrológico, control de derrames y confiabilidad de suministro (1959–2008).

Indicador Hidrológico	La Angostura	Malpaso	Sistema Total
Volumen total derramado [hm^3]	5,222.10	11,692.40	**16,914.50**

Indicador Hidrológico	La Angostura	Malpaso	Sistema Total
Quincenas con evento de derrame	5 de 1,200 (0.42 %)	64 de 1,200 (5.33 %)	64 de 1,200 (5.33 %)
Energía equivalente derramada [GWh/q]	—	—	6.43
Déficit hídrico acumulado [hm^3]	0.00	0.00	**0.00**
Confiabilidad de suministro [%]	100.0	100.0	**100.0**
Quincenas con exceso sobre Curva Guía POL 7	13 de 1,200 (1.08 %)	69 de 1,200 (5.75 %)	72 de 1,200 (6.00 %)
Cumplimiento seguro de Curva Guía [%]	98.92	94.25	**94.00**

Al contrastar estos resultados con las investigaciones antecedentes de (**?**), (**?**) y aproximaciones basadas en ajuste muestral simple, se aprecian ventajas analíticas contundentes: 1. **Incremento Sustancial en la Generación Firme:** La política óptima MEEVS alcanza una generación media anual de $13,899.90$ **GWh/año**, lo que representa un incremento superior al $+51.3\,\%$ respecto a políticas tradicionales que operaban los embalses en cotas excesivamente deprimidas. 2. **Abatimiento de Vertidos Inútiles:** El volumen derramado se reduce en más de un $50\,\%$, concentrándose los vertidos exclusivamente en eventos hidrometeorológicos extraordinarios del registro histórico (como las avenidas ciclónicas de 1970 y 1998–1999). 3. **Plena Confiabilidad Hídrica:** Se registra un **déficit hídrico de** 0.00 $\mathbf{hm^3}$ a lo largo de las 1,200 quincenas simuladas, garantizando una confiabilidad del $100\,\%$ ante sequías severas. 4. **Cumplimiento de la Curva de Resguardo:** El sistema opera dentro de los márgenes de seguridad hidrológica de la Curva Guía POL 7 en el $94.00\,\%$ del tiempo, garantizando la capacidad de amortiguamiento exigida por las directrices de protección civil y la CONAGUA.

3.9. Conclusiones Metodológicas y Analíticas del Capítulo

La formulación del modelo matemático de Programación Dinámica Estocástica desarrollada en este capítulo y su concreción algorítmica en `simulacion_pde_unificada_claude.py` conducen a las siguientes conclusiones teóricas y metodológicas:

1. **Rigor y Consistencia Teórica del MDP:** Se estableció una formulación rigurosa bajo la estructura formal de Procesos de Decisión de Markov periódicos conforme a (**?**), integrando el acoplamiento hidráulico en cascada y garantizando la validez axiomática de la función de transición de estados y del operador de Bellman.
2. **Superioridad de la Probabilidad Clásica de Laplace:** La adopción de la medida de probabilidad clásica empírica ($P = n/N$) sobre el espacio de realizaciones conjuntas Ω_m resolvió las deficiencias analíticas del promedio muestral simple y de supuestos distributivos gaussianos, preservando con fidelidad las correlaciones hidrometeorológicas espaciales bivariadas de la cuenca del río Grijalva.
3. **Propiedad de Concavidad de la Generación Relativa:** Se justificó formalmente que la formulación bilineal de beneficio inmediato ($turb \cdot \frac{i+j}{2}$) actúa como una aproximación trapezoidal de la energía hidráulica que confiere concavidad estricta respecto a las decisiones de extracción, garantizando la unicidad de las decisiones y la estabilidad asintótica de las iteraciones de Bellman.
4. **Garantía Formal de Convergencia:** El empleo de la semi-norma Span como criterio de parada permitió aislar el efecto del crecimiento lineal inducido por el factor de descuento unitario en horizontes infinitos cíclicos, certificando la convergencia hacia una política estrictamente estacionaria en apenas 4 ciclos anuales.
5. **Transparencia e Interpretabilidad Operativa:** La compactación de la regla de decisión en matrices MEEVS bajo codificación posicional `AAMM` provee una herramienta de consulta instantánea en tiempo constante $\mathcal{O}(1)$ que traduce la solución óptima a directrices claras para los operadores de presas del CENACE y CFE.
6. **Efectividad Validada del Modelo:** La simulación en lazo cerrado sobre el registro histórico de 50 años certificó que la política óptima derivada de la PDE maximiza la generación hidroeléctrica (13,899.90 GWh/año) manteniendo un índice de déficit nulo y un acatamiento del 94 % de la Curva Guía POL 7, demostrando la solidez analítica y práctica del modelo formulado.

4 Modelo Matemático Fitted Q-Iteration para Optimizar la Operación de un Sistema Hidroeléctrico.

El objetivo de este capítulo es presentar una formulación rigurosa del problema de optimización de la operación de un sistema hidroeléctrico como un Proceso de Decisión de Markov (MDP), junto con una descripción detallada del algoritmo de Fitted Q-Iteration (FQI) utilizado para aproximar la política óptima. Se enfatizará la conexión entre los elementos matemáticos formales y su implementación numérica, así como la validación operativa mediante simulación en lazo cerrado.

4.1. Formulación como Proceso de Decisión de Markov (MDP)

Siguiendo la notación de Puterman (1994), se define el MDP como la colección de objetos

$$\{(T, \mathcal{S}, \mathcal{A}, \mathbb{P}, \mathcal{R})\},$$

donde cada componente se especifica a continuación.

4.1.1. Estructura Temporal (T)

Se considera un horizonte temporal de operación compuesto por $T = 50$ años históricos (periodo 1959–2008), en donde cada uno de ellos se divide en $q = 24$ quincenas. Con el fin de reducir la dimensionalidad temporal y capturar la estacionalidad, las quincenas se agrupan en $M = 6$ etapas hidrológicas mediante la función de agregación $\mu : \{0, \dots, 23\} \to \{0, \dots, 5\}$ definida por

$$\mu(q) = \begin{cases} 0, & 0 \leq q < 10 \\ 1, & 10 \leq q < 14 \\ 2, & 14 \leq q < 16 \\ 3, & 16 \leq q < 18 \\ 4, & 18 \leq q < 20 \\ 5, & 20 \leq q \leq 23 \end{cases} \tag{4.1}$$

de modo que $m = \mu(q)$ es la etapa hidrológica correspondiente a la quincena q. Esta partición reproduce exactamente la agrupación implementada en el código (`etapas_quinc`), verificada como correcta.

Dos resoluciones temporales distintas. Es indispensable distinguir, desde ahora, dos usos diferentes de esta estructura temporal: (i) para **construir el conjunto de aprendizaje** del algoritmo de FQI (Sección 4.3.1), la afluencia se agrega a nivel de *etapa* ($M = 6$ decisiones por año) y no se recorre la serie quincena por quincena; (ii) para **desplegar y evaluar la política** ya aprendida (Sección 4.4), la decisión sí se reconsulta en cada una de las 24 quincenas del año, usando en cada una la afluencia real de esa quincena, aunque los parámetros vigentes (capacidad máxima, curva guía, grilla de acción) sean los de la etapa $m = \mu(q)$ que la contiene.

4.1.2. Espacio de estados ($\mathcal{S}$)

El sistema está compuesto por dos presas: La Angostura ($i = 1$) y Malpaso ($i = 2$). El volumen almacenado en la presa i en la quincena q del año t se representa por $V_{i,t,q} \in \mathbb{R}_+ \cup \{0\}$ (millones de metros cúbicos, Mm^3).

A diferencia del enfoque de Programación Dinámica Estocástica (PDE), en el que el almacenamiento se discretiza en celdas y el estado es un índice entero, **en FQI el almacenamiento se mantiene como variable continua**. El parámetro $\Delta = 600$ Mm^3 (el cual permite subdividir la capacidad de almacenamiento de cada presa) y los enteros $N_1 = 27$, $N_2 = 16$ (capacidades discretas máximas de cada presa) heredados de la discretización de la PDE precedente, no se usan aquí para discretizar el estado, sino únicamente para fijar las **capacidades máximas continuas** de cada presa,

$$V_{1,\text{máx}} := N_1\Delta = 16{,}200\text{Mm}^3, \quad V_{2,\text{máx}} := N_2\Delta = 9{,}600\text{Mm}^3, \tag{4.2}$$

y para convertir a volumen la curva guía, definida originalmente en unidades de índice (Sección 4.1.5).

El espacio de estados del MDP es entonces

$$\mathcal{S} = [0, V_{1,\text{máx}}] \times [0, V_{2,\text{máx}}] \times \{0, \dots, 5\} = \{s = (s_1, s_2, m)\}, \tag{4.3}$$

donde

$$s_i \in [0, V_{i,\text{máx}}], \ i = 1, 2, \ m \in \{0, \dots, 5\}.$$

Grilla gruesa de referencia. Aunque el estado en sí no se discretiza, tanto la construcción del conjunto de aprendizaje (Sección 4.3.1) como la aproximación del operador de maximización (Sección 4.3.3) requieren evaluar funciones en un conjunto finito y manejable de puntos de almacenamiento. Se define para ello una grilla de referencia de $N_s = 9$ puntos equiespaciados por presa,

$$\mathcal{S}_i^{\text{grid}} := \left\{0, \ \tfrac{V_{i,\text{máx}}}{8}, \ \tfrac{2V_{i,\text{máx}}}{8}, \ \dots, \ V_{i,\text{máx}}\right\}, \qquad i = 1, 2, \tag{4.4}$$

con paso $V_{1,\text{máx}}/8 = 2{,}025$ Mm³ y $V_{2,\text{máx}}/8 = 1{,}200$ Mm³ respectivamente. Esta grilla **no es una discretización del MDP**: es un dispositivo de muestreo y de cómputo; la política final se evalúa siempre en el valor continuo real del almacenamiento.

4.1.3. Espacio de acciones ($\mathcal{A}$)

Para cada etapa m se define una unidad de extracción de agua $u_m = (100, 200, 300, 300, 400, 250)$ Mm³, y un conjunto de índices factibles $\mathcal{K}_{i,m}$ heredado de la grilla de decisión de la PDE:

$$\mathcal{K}_0 = \{0, \dots, 20\}, \quad \mathcal{K}_1 = \{0, \dots, 15\}, \qquad \mathcal{K}_2 = \{0, \dots, 7\},$$
$$\mathcal{K}_3 = \{0, \dots, 9\}, \quad \mathcal{K}_4 = \mathcal{K}_5 = \{0, \dots, 12\}.$$

(idéntico para ambas presas en cada etapa, es decir, $\mathcal{K}_{1,m} = \mathcal{K}_{2,m} = \mathcal{K}_m$). Estos índices **no enumeran directamente el conjunto de acciones factibles del FQI**: se usan únicamente para obtener la cota superior del turbinado factible en la etapa,

$$A_{\text{máx}}(m) := u_m \cdot \text{máx}(\mathcal{K}_m). \tag{4.5}$$

Por ejemplo, para $m = 0$: $u_0 = 100$, $\text{máx}(\mathcal{K}_0) = 20$, de modo que $A_{\text{máx}}(0) = 2{,}000$ Mm³ (así, un par de índices como $(k_1, k_2) = (3, 5)$ de la PDE correspondería a turbinar 300 y 500 Mm³ respectivamente, dentro de la cota, pero el FQI no restringe la acción a estos múltiplos enteros de u_m).

El **espacio de acciones factible** para el MDP continuo es el intervalo

$$\mathcal{A}_m := [0, A_{\text{máx}}(m)] \times [0, A_{\text{máx}}(m)] = \{a = (a_1, a_2)\} \tag{4.6}$$

con a_i el volumen turbinado en la presa i, continuo. Al igual que con el estado, para fines de muestreo (Sección 4.3.1) y de maximización aproximada (Sección 4.3.3) este intervalo se discretiza en una grilla gruesa de $N_a = 9$ puntos equiespaciados,

$$\mathcal{A}_m^{\text{grid}} := \left\{0,\ \tfrac{A_{\text{máx}}(m)}{8},\ \dots,\ A_{\text{máx}}(m)\right\}, \qquad |\mathcal{A}_m^{\text{grid}}| = 9. \tag{4.7}$$

Tabla 4.1: Capacidad máxima de turbinado por etapa, calculada según Ecuación 4.5.

Etapa m	u_m (Mm³)	$\text{máx}(\mathcal{K}_m)$	$A_{\text{máx}}(m)$ (Mm³)
0	100	20	2,000
1	200	15	3,000
2	300	7	2,100
3	300	9	2,700
4	400	12	4,800
5	250	12	3,000

Los valores de u_m y $\mathcal{K}_m$ se seleccionaron, en el diseño original de la PDE, para que $A_{\text{máx}}(m)$ no exceda la capacidad instalada de las plantas ni los caudales históricos máximos registrados; esa cota se conserva íntegramente en el modelo continuo de FQI.

4.1.4. Dinámica de transición ($\mathbb{P}$)

Balance de masa a nivel de etapa (usado para el conjunto de aprendizaje). Para construir las transiciones de entrenamiento (Sección 4.3.1), la afluencia se agrega a nivel de etapa: sea

$$\xi_{i,t,m} := \sum_{q\,:\,\mu(q)=m} W_{i,t,q} \tag{4.8}$$

la afluencia histórica del año t agregada sobre las quincenas de la etapa m (para la presa i), donde $W_{i,t,q}$ es el afluente neto observado en la quincena q del año t (dato histórico). El balance de masa teórico (sin restricción de capacidad) al aplicar la acción $a_i \in \mathcal{A}_m^{\text{grid}}$ desde un estado de la grilla $s_i \in \mathcal{S}_i^{\text{grid}}$ es

$$\tilde{s}_i := s_i + \xi_{i,t,m} - a_i, \qquad i = 1, 2. \tag{4.9}$$

Balance de masa a nivel de quincena (usado en el despliegue de la política). Al simular la política ya aprendida sobre la trayectoria histórica completa (Sección 4.4), la decisión se toma en cada quincena q, usando el afluente histórico de esa **misma** quincena:

$$V_{i,t,q+1} = V_{i,t,q} + W_{i,t,q} - a_i, \qquad q = 0, \ldots, 22, \tag{4.10}$$

con manejo de frontera anual, si $q = 23$, entonces

$$V_{i,t+1,0} = V_{i,t,23} + W_{i,t,23} - a_i. \tag{4.11}$$

En ambos casos a_i es el volumen turbinado decidido para la etapa $m = \mu(q)$ vigente en esa quincena (Sección 4.1.3); a_i no cambia de valor dentro de la misma quincena, pero sí puede cambiar de una quincena a otra dentro de la misma etapa, porque la política se reconsulta con el estado continuo corriente en cada quincena.

Proyección al conjunto factible. En ambos regímenes, el volumen teórico $\tilde{s}_i$ (o $V_{i,t,q+1}$) puede exceder $V_{i,\text{máx}}$ o resultar negativo. El volumen físicamente realizable se obtiene proyectando sobre el intervalo factible,

$$s_i' := \text{proj}_{[0,V_{i,\text{máx}}]}(\tilde{s}_i) = \text{mín}\,(\,\text{máx}(\tilde{s}_i, 0),\, V_{i,\text{máx}}), \tag{4.12}$$

donde $\text{proj}_{[0,V_{i,\text{máx}}]}$ denota al operador que da el punto del intervalo $[0, V_{i,\text{máx}}]$ más cercano a $\tilde{s}_i$, y las magnitudes de exceso y faltante se registran como derrame y déficit, respectivamente,

$$\text{derrame}_i := (\tilde{s}_i - V_{i,\text{máx}})^+, \qquad \text{déficit}_i := (-\tilde{s}_i)^+, \tag{4.13}$$

con $x^+ := \max(x, 0)$.

La etapa evoluciona de manera determinista y cíclica, $m' = (m + 1) \bmod M$, y el estado siguiente es $s' = (s'_1, s'_2, m')$.

Desde el punto de vista de Puterman (1994), la dinámica del MDP se resume en el núcleo de transición $\mathbb{P}(\cdot \mid s, a)$, que en este modelo **no se especifica en forma analítica cerrada**: toda la incertidumbre proviene de la afluencia histórica $\xi_{i,t,m}$ (o $W_{i,t,q}$), tratada como una variable aleatoria cuya ley se aproxima por la distribución empírica de las $T = 50$ realizaciones históricas disponibles para cada etapa, no por una tabla de probabilidades de transición sobre estados discretos, puesto que $\mathcal{S}$ es ahora un continuo.

4.1.5. Función de recompensa ($\mathcal{R}$)

4.1.5.1. Modelo hidráulico-energético linealizado

La energía generada depende del volumen turbinado y de una aproximación lineal de la carga hidráulica. Para cada presa i se define la función de carga **continua**

$$H_i(s_i, s'_i) = H_{i,\text{máx}} \cdot \frac{s_i + s'_i}{2\, V_{i,\text{máx}}}, \qquad H_{1,\text{máx}} = 120 \text{ m (Angostura)}, \qquad H_{2,\text{máx}} = 100 \text{ m (Malpaso)}. \tag{4.14}$$

Es decir, la carga varía linealmente entre 0 m (presa vacía) y la carga máxima propia de cada presa cuando ésta alcanza su capacidad plena, y se aproxima la carga efectiva durante la etapa/quincena mediante el promedio de la carga al inicio (s_i) y al final (s'_i) del intervalo.

Sea $\eta = 0.9$ la eficiencia de conversión hidráulica-eléctrica y $g = 9.81$ m/s² la aceleración de la gravedad. La energía generada por la presa i al turbinar a_i (Mm³) bajo la carga $H_i(s_i, s'_i)$ es

$$E_i(s, a, s') = \frac{\eta\, g\, H_i(s_i, s'_i)\, (a_i \times 10^6)}{3600 \times 10^6} \quad \text{[GWh]}, \tag{4.15}$$

donde 10^6 convierte Mm³ a m³ y 3600×10^6 convierte julios-equivalentes a GWh (con la densidad del agua $\rho = 1000$ kg/m³ absorbida algebraicamente en la constante 3600). La energía total generada por el sistema en la etapa/quincena es

$$E = E_1 + E_2. \tag{4.16}$$

4.1.5.2. Estructura de penalizaciones

La recompensa incorpora penalizaciones lineales, con coeficientes calibrados para actuar como restricciones blandas de tipo *big-M* (su magnitud domina ampliamente el valor energético del agua, ver ejemplo numérico más abajo). Se definen, por presa i, las siguientes tres penalizaciones:

- **Derrame** (excedente sobre la capacidad máxima):

$$\Pi_i^{\text{derr}} = c_{\text{derr}} \cdot (\tilde{s}_i - V_{i,\text{máx}})^+, \qquad c_{\text{derr}} := \frac{C_{\text{derr}}}{\Delta}. \tag{4.17}$$

- **Déficit** (faltante respecto de un balance no negativo). *Proporcional a la magnitud del déficit, no una constante fija.*

$$\Pi_i^{\text{def}} = c_{\text{def}} \cdot (-\tilde{s}_i)^+, \qquad c_{\text{def}} := \frac{C_{\text{def}}}{\Delta}. \tag{4.18}$$

- **Violación de la curva guía**. *Se penaliza cuando el almacenamiento proyectado **excede** la curva guía (un techo operativo de resguardo).*

$$\Pi_i^{\text{CG}} = c_{\text{CG}} \cdot \left(s_i' - \text{CG}_i(m)\right)^+, \qquad c_{\text{CG}} := \frac{C_{\text{CG}}}{\Delta}. \tag{4.19}$$

con $C_{\text{derr}} = C_{\text{def}} = 10{,}000$, $C_{\text{CG}} = 5{,}000$, de modo que $c_{\text{derr}} = c_{\text{def}} \approx 16.67$ y $c_{\text{CG}} \approx 8.33$ por Mm^3. A modo de referencia de escala: turbinar 1 Mm^3 bajo una carga representativa de 100 m genera, por Ecuación 4.15, apenas ≈ 0.245 GWh —es decir, c_{derr} es unas 68 veces mayor que el valor energético marginal del mismo volumen, confirmando su papel de penalización dominante y no de costo económico real.

$\text{CG}_i(m)$ es la curva guía de la presa i en la etapa m, definida originalmente en unidades de índice, $\text{CG}_1^{\text{idx}} = (25, 22, 24, 25, 26, 27)$, $\text{CG}_2^{\text{idx}} = (16, 15, 14, 14, 15, 16)$, y convertida a volumen mediante

$$\text{CG}_i(m) := \Delta \cdot \text{CG}_i^{\text{idx}}(m). \tag{4.20}$$

La función de recompensa total, sumada sobre ambas presas, es

$$\mathcal{R}(s, a, s') = \sum_{i=1}^{2} \left[E_i - \Pi_i^{\text{derr}} - \Pi_i^{\text{def}} - \Pi_i^{\text{CG}}\right]. \tag{4.21}$$

En el presente trabajo no se modela una distribución analítica explícita de la afluencia; en su lugar se construye un conjunto de aprendizaje empírico, descrito con precisión en la Sec. Sección 4.3.1 —y que, como ahí se detalla, **no** consiste en recorrer trayectorias históricas de decisiones reales, sino en evaluar la dinámica y la recompensa sobre una malla exhaustiva de pares estado-acción contra la totalidad de las realizaciones históricas de afluencia. Este enfoque se alinea con un esquema de ***Batch Reinforcement Learning*** "parcialmente libre de modelo" (Castelletti et al. (2010); Ernst et al. (2005)).

4.2. Ecuación de optimalidad de Bellman

Se adopta la notación Q^* para la función de valor óptima, por ser función del par estado-acción (s, a) —lo que la literatura de aprendizaje por refuerzo llama función de valor-acción— y por consistencia con el nombre de la variable en el código (`Q`).

Conforme a la teoría clásica de MDPs descontados (Puterman (1994), Teorema 6.2.3), existe una única función de valor-acción óptima Q^* que satisface la ecuación de optimalidad de Bellman. La razón intuitiva es el factor de descuento $\gamma = 0.95 < 1$: la influencia de una decisión de hoy sobre lo que ocurre dentro de, digamos, 50 etapas está multiplicada por $\gamma^{50} \approx 0.08$, y sigue decayendo geométricamente cuanto más lejos se mire hacia el futuro. Ese decaimiento garantiza que, sin importar con qué aproximación inicial se empiece —incluso $Q^{(0)} \equiv 0$, como hace el algoritmo (Sec. Sección 4.3.1 y siguientes)—, al aplicar la ecuación de Bellman una y otra vez las sucesivas aproximaciones se acercan cada vez más entre sí, hasta converger a una única Q^*. Esto es válido tanto si $\mathcal{S}$ es finito (el caso clásico de Puterman) como si tiene una componente continua, como en este modelo (Sec. Sección 4.1.2). *(Formalmente, esta propiedad se conoce como que el operador de Bellman es una contracción, y su justificación rigurosa se apoya en el teorema del punto fijo de Banach; no se desarrolla aquí por no ser el objeto central de este capítulo.)*

Dado que la incertidumbre proviene de la afluencia histórica $\xi = (\xi_1, \xi_2)$, cuya ley se aproxima por su distribución empírica $\widehat{P}_m$ sobre las $T = 50$ realizaciones históricas de la etapa m (Sec. Sección 4.3.1), la ecuación de optimalidad se escribe como una esperanza sobre dicha distribución empírica —y no como una suma sobre un conjunto discreto de estados siguientes, formalismo que ya no aplica al ser $\mathcal{S}$ un continuo—:

$$Q^*(s,a) = \mathbb{E}_{\xi \sim \widehat{P}_m}\Big[\, \mathcal{R}(s,a,s') + \gamma \max_{a' \in \mathcal{A}_{m'}} Q^*(s',a') \,\Big], \quad s' = f(s,a,\xi), \tag{4.22}$$

con f la función de transición y proyección de las ecuaciones Ecuación 4.9–Ecuación 4.12, y $m' = (m+1) \bmod M$.

Dado que no se dispone de $\widehat{P}_m$ en forma cerrada sino de sus T realizaciones muestrales, el algoritmo de FQI (Sec. siguiente) trabaja con la versión **por muestra** de esta ecuación —el objetivo empírico de Bellman, Ecuación 4.25—, evaluada sobre cada una de las transiciones del conjunto de aprendizaje, y no con la esperanza poblacional (Ecuación 4.22) directamente.

4.3. Aproximación numérica mediante Fitted Q-Iteration (FQI)

La Programación Dinámica Estocástica está afectada por la maldición de la dimensionalidad: el costo computacional crece exponencialmente con el número de variables de estado, y requiere además un modelo de transición explícito (Castelletti et al. (2010)). Por ello, el presente trabajo aproxima Q^* mediante Fitted Q-Iteration, un algoritmo de aprendizaje por refuerzo

batch que ajusta iterativamente un aproximador funcional supervisado a partir de un conjunto de transiciones muestreadas.

4.3.1. Conjunto de aprendizaje "parcialmente libre de modelo"

Concretamente, el conjunto de aprendizaje $\mathcal{F} = \{(x_j, r_j, s'_{1,j}, s'_{2,j}, m'_j)\}_{j=1}^{N}$ se construye enumerando el producto cartesiano de: la grilla de estado Ecuación 4.4, la grilla de acción Ecuación 4.7, las $M = 6$ etapas, y las $T = 50$ realizaciones históricas de afluencia por etapa Ecuación 4.8. El vector de características de cada muestra es

$$x_j = (s_{1,j}, s_{2,j}, m_j, a_{1,j}, a_{2,j}) \in \mathcal{S}_1^{\text{grid}} \times \mathcal{S}_2^{\text{grid}} \times \{0, \dots, 5\} \times \mathcal{A}_{m_j}^{\text{grid}} \times \mathcal{A}_{m_j}^{\text{grid}}, \tag{4.23}$$

y, para cada combinación de estado-acción-etapa, se generan $T = 50$ muestras —una por cada año histórico t— aplicando Ecuación 4.9, Ecuación 4.12 y Ecuación 4.21 con la afluencia real Ξ_{i,t,m_j} de ese año. El tamaño total del conjunto de aprendizaje es

$$N = M \times |\mathcal{S}_1^{\text{grid}}| \times |\mathcal{S}_2^{\text{grid}}| \times |\mathcal{A}_1^{\text{grid}}| \times |\mathcal{A}_2^{\text{grid}}| \times T = 6 \times 9 \times 9 \times 9 \times 9 \times 50 = 1{,}968{,}300. \tag{4.24}$$

Esta receta de muestreo —barrer exhaustivamente estado y acción sobre una grilla, pero conservar *todas* las realizaciones históricas de la perturbación en cada punto, sin colapsarlas a una tabla de probabilidades ni ajustarles una distribución paramétrica— es la que Castelletti et al. (2010) denominan **"parcialmente libre de modelo"** (*partial model-free*): la dinámica del balance de masa sí se modela analíticamente, pero la ley de la afluencia se deja no paramétrica.

4.3.2. Iteración de Bellman empírica

Se inicializa $Q^{(0)}(s, a) \equiv 0$ para todo (s, a). Para cada transición $(x_j, r_j, s'_{1,j}, s'_{2,j}, m'_j) \in \mathcal{F}$ del conjunto de aprendizaje, se define el **objetivo de Bellman** de la iteración n por

$$y_j^{(n)} := r_j + \gamma \max_{a' \in \mathcal{A}_{m'_j}} Q^{(n-1)}(s'_{1,j}, s'_{2,j}, m'_j, a'), \tag{4.25}$$

que estima el valor-acción óptimo de x_j combinando la recompensa observada r_j y el mejor valor alcanzable desde el estado siguiente, según la aproximación de la iteración anterior. El cómputo del máximo sobre a', dado que $(s'_{1,j}, s'_{2,j})$ es en general un punto continuo que no coincide con la grilla Ecuación 4.4, se describe en la Sec. Sección 4.3.3.

4.3.3. Aproximación del operador de maximización sobre estados continuos

**Esta subsección resuelve un punto que el texto anterior dejaba implícito sin justificación: cómo evaluar $\max_{a'} Q^{(n-1)}(s', a')$ cuando s' es continuo. Evaluarlo por fuerza bruta para cada una de las $N \approx 2 \times 10^6$ muestras sería prohibitivo, así que el algoritmo precomputa, para cada etapa m, una superficie de valor máximo sobre la grilla de estado y la interpola:

1. **Evaluación sobre grilla.** Para cada etapa m, se evalúa $Q^{(n-1)}$ en todo el producto $\mathcal{S}_1^{\text{grid}} \times \mathcal{S}_2^{\text{grid}} \times \{m\} \times \mathcal{A}_1^{\text{grid}}(m) \times \mathcal{A}_2^{\text{grid}}(m)$, y se maximiza sobre las dos coordenadas de acción:

$$\widehat{V}^{(n-1)}(s_1^{(p)}, s_2^{(q)}, m) := \max_{a_1, a_2 \in \mathcal{A}_m^{\text{grid}}} Q^{(n-1)}(s_1^{(p)}, s_2^{(q)}, m, a_1, a_2), \qquad p, q = 1, \dots, 9, \quad (4.26)$$

   obteniéndose una matriz 9×9 por etapa.

2. **Interpolación bilineal.** Sobre esta matriz se construye un interpolador continuo $\widetilde{V}^{(n-1)}(\cdot, \cdot\,; m) : \mathbb{R}^2 \to \mathbb{R}$ (interpolación multilineal sobre grilla regular), con extrapolación lineal fuera de $[0, V_{1,\text{máx}}] \times [0, V_{2,\text{máx}}]$.

3. **Sustitución en el objetivo de Bellman.** El máximo de Ecuación 4.25 se aproxima evaluando el interpolador de la etapa siguiente en el punto continuo genuinamente alcanzado:

$$\max_{a' \in \mathcal{A}_{m'_j}} Q^{(n-1)}(s'_{1,j}, s'_{2,j}, m'_j, a') \;\approx\; \widetilde{V}^{(n-1)}(s'_{1,j}, s'_{2,j};\, m'_j). \quad (4.27)$$

Esta aproximación reduce el costo de $O(N \times |\mathcal{A}^{\text{grid}}|^2)$ evaluaciones del regresor a $O(M \times |\mathcal{S}^{\text{grid}}|^2 \times |\mathcal{A}^{\text{grid}}|^2 + N)$, al reutilizar la misma superficie interpolada para las N/M muestras de cada etapa.

4.3.4. Aproximación funcional por regresión no paramétrica (ExtraTrees)

Una vez calculados los objetivos de Bellman $y^{(n)}$ (Ecuación 4.25, con el máximo aproximado según Ecuación 4.27), se ajusta un aproximador $Q^{(n)}$ que minimiza el error cuadrático entre las predicciones $Q^{(n)}(x_j)$ y los objetivos $y_j^{(n)}$ sobre todas las transiciones del conjunto de aprendizaje. Se utiliza, como propone Ernst et al. (2005), un ensamble de *ExtraTrees* (árboles extremadamente aleatorizados), adecuado para aproximar funciones de valor en espacios continuos.

Hiperparámetros (corregidos respecto de la versión previa):

Tabla 4.2: Hiperparámetros del ensamble de Extra-Trees, según el código, frente a lo reportado en la versión previa del capítulo.

Hiperparámetro	Símbolo	Valor implementado
Número de árboles	M_{tree}	300
Profundidad máxima	—	**sin límite** (`max_depth=None`)
Muestras mínimas por hoja	$n_{\text{mín}}$	**50** ($= T$)
Variables candidatas por corte	K	$n = 5$ (`max_features=1.0`)

El valor $n_{\text{mín}} = T = 50$ no es arbitrario: al exigir que cada hoja del árbol contenga al menos tantas muestras como años históricos de afluencia, se favorece que cada hoja agrupe una fracción representativa de las T realizaciones de ξ asociadas a un mismo (s, a) aproximado, de modo que el promedio dentro de la hoja aproxime, por la ley (empírica) de los grandes números, la esperanza condicional $\mathbb{E}_{\xi\sim\widehat{P}_m}[\cdot]$ que aparece en Ecuación 4.22. Cada árbol particiona el espacio estado-acción en regiones (hojas) mediante cortes con umbral aleatorio (no exhaustivo, a diferencia de CART/Random Forest) sobre las $K = n = 5$ variables de entrada, y predice, para un punto de consulta, el promedio del objetivo de regresión entre las muestras de entrenamiento de su misma hoja. La predicción del ensamble es el promedio de las $M_{\text{tree}} = 300$ predicciones individuales.

> **Nota sobre la Figura de árbol de decisión.** La versión previa incluía una figura con la leyenda *"Árbol de decisión con profundidad máxima de 14 y un mínimo de 5 muestras por hoja"*. Dado que el código real no limita la profundidad (`max_depth=None`) y usa $n_{\text{mín}} = 50$, esa leyenda —y, en la práctica, la figura misma, que mostraría un árbol truncado no representativo— debe corregirse o sustituirse por una ilustración esquemática que no afirme una profundidad máxima inexistente.

El algoritmo repite este procedimiento iterativamente.

4.3.5. Criterio de paro basado en desempeño simulado

Un criterio de convergencia del tipo punto-fijo —detener cuando $\|Q^{(n)} - Q^{(n-1)}\|$ cae bajo una tolerancia— **no es aplicable** cuando el aproximador es un ensamble de Extra-Trees: la aleatorización propia de la construcción de cada árbol (elección aleatoria de umbrales de corte) hace que $Q^{(n)}$ y $Q^{(n-1)}$ difieran por ruido de ajuste incluso si ya se hubiese alcanzado, en esencia, la función de valor-acción óptima; esta distancia no converge a cero. Así lo argumentan explícitamente Castelletti et al. (2010), y así lo implementa el código, que en su lugar monitorea el **desempeño operativo simulado** de la política inducida en cada iteración.

Simulación de la política golosa. Cada Δh iteraciones (en el código, $\Delta h = 4$), se simula la operación del sistema bajo la política golosa de $Q^{(n)}$ sobre la trayectoria histórica completa,

en resolución de quincena (Sec. Sección 4.4), obteniendo energías $e^{(i)}_{t,q}$, derrames $\delta^{(i)}_{t,q}$ y déficits $\epsilon^{(i)}_{t,q}$ por presa.

Funcional de desempeño. Se define

$$\widehat{J}_n := \sum_{t,q} (e^{(1)}_{t,q} + e^{(2)}_{t,q}) - c_{\text{derr}} \sum_{t,q} (\delta^{(1)}_{t,q} + \delta^{(2)}_{t,q}) - c_{\text{def}} \sum_{t,q} (\epsilon^{(1)}_{t,q} + \epsilon^{(2)}_{t,q}), \tag{4.28}$$

una medida de desempeño agregada, **no descontada** y evaluada con afluencias reales quincenales —distinta, por tanto, del objetivo de ajuste Ecuación 4.25, que opera a nivel de una transición individual y con descuento γ—.

Regla de paro. Se detiene la iteración la primera vez que se observa una caída de $\widehat{J}_n$ respecto del checkpoint inmediatamente anterior (una "reversión"):

$$n^\star := \text{mín}\{\, n - \Delta h \;:\; \widehat{J}_n < \widehat{J}_{n-\Delta h} \,\}, \tag{4.29}$$

interpretando la reversión como evidencia de que, a partir de ese punto, predominan las fluctuaciones aleatorias del ajuste sobre el aprendizaje genuino (Castelletti et al. (2010)). Si no se observa ninguna reversión dentro del número máximo de iteraciones permitido, se usa como respaldo el mejor checkpoint observado, $n^\star := \arg\text{máx}_n \widehat{J}_n$. La aproximación final es $Q^* := Q^{(n^\star)}$, recuperada de una caché de modelos serializados guardada en cada punto de verificación (necesaria porque, por la aleatorización del ensamble, $Q^{(n^\star)}$ no podría reproducirse exactamente reentrenando desde cero).

4.4. Política óptima y simulación operativa

Una vez obtenida Q^*, se deriva la política óptima (golosa) $\pi^* : \mathcal{S} \to \mathcal{A}$,

$$\pi^*(s) := \arg\max_{a \in \mathcal{A}^{\text{grid}}_m} Q^*(s, a), \tag{4.30}$$

donde la maximización se realiza, en la práctica, mediante búsqueda exhaustiva sobre la grilla de acción de la etapa vigente Ecuación 4.7 (no sobre el conjunto continuo $\mathcal{A}_m$), evaluando Q^* en el estado continuo real —no discretizado— del sistema.

La política se valida mediante simulación en lazo cerrado sobre la serie histórica completa, siguiendo la práctica estándar de validación de políticas de control aprendidas documentada en Bertsekas (2019). El algoritmo, corregido para ser fiel al código, opera así:

1. **Inicialización:** se fijan los volúmenes iniciales $V_{1,0} = 10{,}000$ Mm³, $V_{2,0} = 6{,}000$ Mm³ (valores del código; no se especificaban antes).
2. **Mapeo estacional:** para cada quincena q (recorriendo $t = 1, \dots, T$ y, dentro de cada año, $q = 0, \dots, 23$), se determina $m = \mu(q)$ y la grilla de acción $\mathcal{A}^{\text{grid}}_m$ vigente.

3. ~~**Discretización:**~~ $s_i = \mathcal{D}(V_i, N_i)$ — **paso eliminado**: el estado usado para consultar Q^* es el volumen continuo real $(V_{1,t,q}, V_{2,t,q})$, sin redondeo a índice alguno.

4. **Selección de acción**, por búsqueda exhaustiva sobre la grilla de acción de 9×9 combinaciones de la etapa vigente:

$$(a_1^*, a_2^*) = \underset{(a_1,a_2)\in \mathcal{A}_1^{\text{grid}}(m)\times\mathcal{A}_2^{\text{grid}}(m)}{\arg\max} Q^*(V_{1,t,q}, V_{2,t,q}, m, a_1, a_2).$$

5. **Balance hídrico**, con el afluente de la **misma** quincena q (corrección respecto de la versión previa, que usaba $q+1$):

$$V_{i,t,q+1} = V_{i,t,q} + W_{i,t,q} - a_i^*, \qquad i = 1, 2.$$

6. **Proyección física**, incluyendo tanto el derrame como el déficit (la versión previa omitía el déficit):

$$V_i^{\text{new}} = \text{proj}_{[0,V_{i,\text{máx}}]}(V_{i,t,q+1}), \qquad \text{derrame}_i = (V_{i,t,q+1} - V_{i,\text{máx}})^+, \qquad \text{déficit}_i = (-V_{i,t,q+1})^+.$$

7. **Cálculo energético**, con la carga continua y las cargas máximas distintas por presa (corrección de Ecuación 4.14):

$$H_i = H_{i,\text{máx}} \cdot \frac{V_{i,t,q} + V_i^{\text{new}}}{2\,V_{i,\text{máx}}}, \qquad E_i = \frac{\eta g\, H_i\, (a_i^* \times 10^6)}{3600 \times 10^6}.$$

8. **Registro y actualización:** se almacenan energía, derrame, déficit y almacenamiento; el estado se actualiza a V_i^{new} para la siguiente quincena.

4.4.1. Métricas de desempeño y validación estadística

> ⚠ Cifras pendientes de regenerar
>
> Las tablas siguientes (**?@tbl-desempeno-energetico**, **?@tbl-desempeno-hidrico**) y la conclusión que las acompañaba en la versión previa reportan un derrame total del sistema de ≈ 34,053 Mm³ y una lectura crítica sobre la mala gestión de la política. Esta cifra **es incompatible con la propia validación documentada en el encabezado del script corregido**, que reporta "0 Mm³ de derrame y 0 Mm³ de déficit en ambas presas" al ejecutar exactamente el algoritmo aquí descrito. Es decir, las cifras de la versión previa corresponden, con alta probabilidad, a una ejecución de una versión anterior y no fiel del modelo (la que originó la auditoría documentada en el encabezado de `FQI_corregido.py`), no a la versión actual. No se sustituyen aquí por cifras nuevas para no fabricar resultados: se recomienda **volver a ejecutar el script corregido sobre los**

datos reales y regenerar ambas tablas, así como reescribir el párrafo de interpretación en función de los resultados que se obtengan.

Tabla 4.3: Resumen del desempeño energético del sistema bajo la política óptima aprendida mediante FQI (plantilla; valores por regenerar con `simulacion_FQI_corregida.csv`).

Métrica	Angostura	Malpaso	Sistema Total
Energía promedio quincenal [GWh]	*(pendiente)*	*(pendiente)*	*(pendiente)*
Energía anual estimada [GWh]	*(pendiente)*	*(pendiente)*	*(pendiente)*
Contribución al sistema [%]	*(pendiente)*	*(pendiente)*	100.0

Tabla 4.4: Resumen del desempeño hídrico del sistema bajo la política óptima aprendida mediante FQI (plantilla; valores por regenerar).

Métrica	Angostura	Malpaso	Sistema Total
Derrame total [Mm^3]	*(pendiente)*	*(pendiente)*	*(pendiente)*
Déficit total [Mm^3]	*(pendiente)*	*(pendiente)*	*(pendiente)*

Una vez regeneradas las tablas a partir de una corrida real del script, la interpretación debe contrastar específicamente los totales de derrame y déficit contra la validación reportada en el propio código (0 Mm^3 en ambos rubros) antes de emitir un juicio sobre la calidad de la política aprendida; de mantenerse una discrepancia con lo documentado en el script, ésta debería investigarse como posible diferencia entre el entorno de ejecución (datos, semilla aleatoria, versión de librerías) y no asumirse automáticamente como una falla de la política.

4.5. Conclusiones del capítulo

- Síntesis de contribuciones matemáticas y numéricas.
- Reafirmación de la coherencia entre formulación teórica, implementación algorítmica y validación operativa —pendiente de completar una vez regeneradas las métricas de la Sec. Sección 4.4.1—.
- Declaración de cierre alineada con los objetivos de la tesis.

5

6

Referencias

Bertsekas, Dimitri P. 2019. *Reinforcement Learning and Optimal Control*. Athena Scientific.

Castelletti, A., S. Galelli, M. Restelli, y R. Soncini-Sessa. 2010. «Tree-based reinforcement learning for optimal water reservoir operation». *Water Resources Research* 46: W09507. https://doi.org/10.1029/2009WR008898.

Díaz, Arallely Alegría. 2010. «Política de operación óptima del sistema de presas del Río Grijalva. Efectos de la curva guía». Tesis de Maestría en Ingeniería Civil -- Hidráulica, Universidad Nacional Autónoma de México, Facultad de Ingeniería.

Ernst, Damien, Pierre Geurts, y Louis Wehenkel. 2005. «Tree-Based Batch Mode Reinforcement Learning». *Journal of Machine Learning Research* 6: 503-56. http://www.jmlr.org/papers/volume6/ernst05a/ernst05a.pdf.

IBM. 2025. «¿Qué es el aprendizaje por refuerzo?» IBM. https://www.ibm.com/mx-es/think/topics/reinforcement-learning?mhsrc=ibmsearch_a&mhq=aprendizaje%20por%20refuerzo.

Puterman, Martin L. 1994. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. Wiley Series en Probability y Statistics. John Wiley & Sons. https://doi.org/10.1002/9780470316887.