

Fitted Q-Iteration: Estimación de niveles de presas

Erika Rubí Jiménez Guzmán
Asesor: Dr. Yofre Hernán García Gómez

2026-07-27

Table of contents

Resumen	3
Introduction	4
I Preliminares	5
1 Fundamentos Matemáticos	6
1.1 Inteligencia Artificial (IA)	6
1.1.1 Aprendizaje Automático	6
2 Fundamentos Hidráulicos	9
II Modelo Matemático	10
3 Modelo Matemático para Optimizar la Operación de un Sistema Hidroeléctrico.	11
3.1 Formulación como Proceso de Decisión de Markov (MDP)	11
3.1.1 Estructura Temporal (T)	11
3.1.2 Espacio de estados y operador de discretización ($\mathcal{S}$)	12
3.1.3 Espacio de acciones ($\mathcal{A}$)	12
3.1.4 Dinámica de transición ($\mathbb{P}$)	13
3.1.5 Función de recompensa ($\mathcal{R}$)	13
3.2 Ecuación de optimalidad de Bellman	15
3.3 Aproximación numérica mediante Fitted Q-Iteration (FQI)	15
3.3.1 Iteración de Bellman empírica	16
3.3.2 Aproximación funcional por regresión no paramétrica (ExtraTrees)	16
3.4 Política óptima y simulación operativa	18
3.4.1 Métricas de desempeño y validación estadística	19
3.5 Conclusiones del capítulo	20
Referencias	23

Resumen

Aquí pondré un resumen de mi tesis, que se llama “Fitted Q-Iteration: Estimación de niveles de presas”.

Introduction

Esta será la introducción.

ejemplo de una cita Puterman (1994).

Part I

Preliminares

1 Fundamentos Matemáticos

1.1 Inteligencia Artificial (IA)

La **Inteligencia Artificial (IA)** es un campo de estudio que se centra en la creación de sistemas capaces de realizar tareas que normalmente requieren inteligencia humana. La IA combina diversas disciplinas, incluyendo matemáticas, estadísticas, informática y neurociencia, para desarrollar algoritmos y modelos que permiten a las máquinas aprender, razonar y tomar decisiones de manera autónoma.

Este campo está dividido en varias subáreas, cada una con su enfoque y aplicaciones específicas. Entre las más destacadas se encuentran el **Aprendizaje Automático (Machine Learning)**, **Aprendizaje Profundo (Deep Learning)**, **Procesamiento del Lenguaje Natural**, **Visión por Computadora**, **Robótica**, entre otras. Cada una de estas subáreas utiliza diferentes técnicas y enfoques para abordar problemas complejos y mejorar la capacidad de las máquinas para interactuar con el mundo que las rodea.

1.1.1 Aprendizaje Automático

En este subcampo de la Inteligencia Artificial, las máquinas aprenden a partir de datos, similar a como lo hacemos nosotros, permitiéndoles mejorar con la experiencia. El aprendizaje automático se basa en algoritmos que identifican patrones y relaciones en los datos, lo que permite a las máquinas hacer predicciones o tomar decisiones sin ser explícitamente programadas para cada tarea específica. Este enfoque ha revolucionado diversas industrias, desde la medicina hasta la economía, al proporcionar herramientas más eficientes y precisas para el análisis de datos y la toma de decisiones.

El aprendizaje automático se clasifica en tres categorías principales: **Aprendizaje Supervisado**, **Aprendizaje No Supervisado** y **Aprendizaje por Refuerzo**, cada una con sus propias técnicas y aplicaciones. Estas categorías permiten abordar diferentes tipos de problemas y desafíos, desde la clasificación de datos hasta la optimización de estrategias en entornos dinámicos.

Definition 1.1 (Aprendizaje Supervisado). Esta categoría se basa en utilizar conjuntos de datos etiquetados (datos de entrada con sus correspondientes salidas) para entrenar modelos

matemáticos que puedan identificar patrones y a partir de ellos predecir resultados futuros sobre datos nuevos.

Este tipo de aprendizaje es principalmente utilizado en:

- **Tareas de clasificación:** los modelos predicen la clase a la que pertenece cada dato. Por ejemplo, identificar si un correo electrónico es spam o no.
- **Regresión:** predicen valores numéricos a partir de datos de entrada. Por ejemplo, predecir el precio de una vivienda basado en sus características.

Definition 1.2 (Aprendizaje No Supervisado). A diferencia del aprendizaje supervisado, en este tipo de aprendizaje no se utilizan datos etiquetados. En su lugar, los algoritmos buscan patrones ocultos o agrupaciones dentro de los datos. Estos modelos son utilizados para tareas específicas como:

- **Agrupamiento (Clustering):** los modelos identifican grupos de datos similares entre sí. Por ejemplo, segmentar clientes en diferentes grupos según sus comportamientos de compra.
- **Reducción de dimensionalidad:** los modelos simplifican los datos manteniendo la mayor cantidad de información posible. Por ejemplo, reducir el número de variables en un conjunto de datos para facilitar su análisis.

Definition 1.3 (Aprendizaje por Refuerzo). En este tipo de aprendizaje automático, los agentes autónomos aprenden a tomar decisiones a partir de la interacción con un entorno en el cual reciben recompensas o penalizaciones según sus acciones. A continuación se presentan los conceptos fundamentales de este tipo de aprendizaje

- **Agente:** es el sistema que toma decisiones y aprende de la experiencia.
- **Entorno:** en donde el agente opera y recibe retroalimentación.
- **Estado:** Situación actual del agente en el entorno.
- **Acción:** Decisión que el agente toma en un estado determinado.
- **Recompensa:** Retroalimentación que el agente recibe después de realizar una acción, indicando si fue beneficiosa o no.
- **Política:** Estrategia que el agente sigue para decidir qué acción tomar en cada estado.

El aprendizaje por refuerzo se centra esencialmente en la relación entre un agente, entorno y el objetivo (lo que se desea lograr). La literatura formula esta relación en términos de un **Proceso de Decisión de Markov (MDP)**.

Véase IBM (2025) para más información sobre estos tipos de aprendizaje y sus aplicaciones.

1.1.1.1 Q-Learning

Existen distintos algoritmos de aprendizaje por refuerzo, entre los cuales se encuentra el **Q-Learning**, este permite a un agente aprender a tomar decisiones en un entorno para maximizar una recompensa acumulada a lo largo del tiempo. Este modelo es model-free, es decir, no requiere un modelo del entorno para aprender, sino que se basa en la experiencia directa del agente a través de la exploración y explotación de su entorno.

2 Fundamentos Hidráulicos

Algoritmo de aprendizaje por refuerzo...

Definition 2.1 (Fitted Q-Iteration). Algoritmo Offline (aprende analizando el historial de experiencias)...

Part II

Modelo Matemático

3 Modelo Matemático para Optimizar la Operación de un Sistema Hidroeléctrico.

El objetivo de este capítulo es presentar una formulación rigurosa del problema de optimización de la operación de un sistema hidroeléctrico como un Proceso de Decisión de Markov (MDP), junto con una descripción detallada del algoritmo de Fitted Q-Iteration (FQI) utilizado para aproximar la política óptima. Se enfatizará la conexión entre los elementos matemáticos formales y su implementación numérica, así como la validación operativa mediante simulación en lazo cerrado.

3.1 Formulación como Proceso de Decisión de Markov (MDP)

Siguiendo la notación de Puterman (1994), se define el MDP como la colección de objetos

$$\{(T, \mathcal{S}, \mathcal{A}, \mathbb{P}, \mathcal{R})\},$$

donde cada componente se especifica a continuación:

3.1.1 Estructura Temporal (T)

Se considera un horizonte temporal de operación compuesto por $T = 50$ años históricos, en donde cada uno de ellos se dividieron en $q = 24$ quincenas. Con el fin de reducir la dimensionalidad temporal y poder capturar la estacionalidad, se agruparon las quincenas en $M = 6$ etapas hidrológicas (segmentación temporal del año) mediante la siguiente función de agregación $\mu : \{0, \dots, q - 1\} \rightarrow \{0, \dots, M - 1\}$ definida por

$$\mu(q) = \begin{cases} 0, & 0 \leq q < 10 \\ 1, & 10 \leq q < 14 \\ 2, & 14 \leq q < 16 \\ 3, & 16 \leq q < 18 \\ 4, & 18 \leq q < 20 \\ 5, & 20 \leq q \leq 23 \end{cases} \quad (3.1)$$

así, la variable $m = \mu(q)$ representará la etapa hidrológica correspondiente a la quincena q .

3.1.2 Espacio de estados y operador de discretización ($\mathcal{S}$)

El sistema está compuesto por dos presas: **La Angostura** ($i = 1$) y **Malpaso** ($i = 2$). El volumen de almacenamiento de cada una de ellas en la quincena q del año t se representará por $V_{i,t,q} \in \mathbb{R}_+ \cup \{0\}$ (Millones de metros cúbicos- Mm^3).

Dado que los datos históricos se utilizan para construir un conjunto de transición empírica, se introduce un operador de discretización uniforme $\mathcal{D}$ del espacio de estados $\mathcal{S}$ mediante el parámetro $\Delta = 600 Mm^3$. Dicha unidad permite subdividir la capacidad de almacenamiento de cada presa en un número manejable de estados. Así, el espacio de estados se define como $\mathcal{S} = \mathcal{S}_1 \times \mathcal{S}_2 \times \{0, \dots, 5\} = \{s = (s_1, s_2, m)\}$ en donde s_i representa el volumen discretizado de la presa i . Tal estado discreto se obtiene mediante el operador de discretización $\mathcal{D} : \mathbb{R} \times \mathbb{N} \rightarrow \{0, \dots, N - 1\}$ definido por

$$s_i = \mathcal{D}(V_{i,t,q}, N_i) := \min \left(\max \left(\left\lfloor \frac{V_{i,t,q}}{\Delta} + \frac{1}{2} \right\rfloor, 0 \right), N_i - 1 \right), \quad (3.2)$$

donde $N_1 = 27$ y $N_2 = 17$ son las capacidades discretas máximas de cada presa.

3.1.3 Espacio de acciones ($\mathcal{A}$)

Para cada etapa m , se define una unidad de extracción de agua $u_m = \{60, 150, 300, 300, 300, 150\}$, así la decisión de operación en la etapa m corresponderá a los niveles de turbinado k_1, k_2 . Cada nivel de turbinado se multiplica por la unidad de extracción u_m , la cual está en Mm^3 , para obtener el volumen de agua extraído en cada presa. Por lo tanto, el espacio de acciones se define como

$$\mathcal{A}_m = \mathcal{K}_{1,m} \times \mathcal{K}_{2,m},$$

donde $\mathcal{K}_{i,m}$ representa el conjunto de niveles de turbinado disponibles para la presa i en la etapa hidrológica m .

Una acción denotada por $a = (k_1, k_2)$, representará el nivel de turbinado aplicado simultaneamente en ambas presas. Por ejemplo, suponga que $m = 0$ entonces

$$u_0 = 60 \quad \text{y} \quad \mathcal{K}_{1,0}, \mathcal{K}_{2,0} = \{0, 1, \dots, 10\},$$

y así $a = (3, 5)$ significaría que Angostura turбина $3 \times 60 = 180 Mm^3$ de agua y Malpaso turбина $5 \times 60 = 300 Mm^3$ de agua. Cabe mencionar que Los valores de u_m y $\mathcal{K}_{i,m}$ se seleccionaron para que el turbinado máximo por etapa hidrológica $k_i \cdot u_m$ no exceda la capacidad instalada de las plantas ni los caudales históricos máximos registrados, garantizando la factibilidad física de todas las acciones evaluadas.

3.1.4 Dinámica de transición ($\mathbb{P}$)

La ecuación de transición continua tras la operación del sistema se define por

$$V_{i,t,q+1} = V_{i,t,q} + W_{i,t,q+1} - k_i u_m, \quad q < 23 \quad (3.3)$$

donde $V_{i,t,q}$ representa el volumen almacenado en la presa i antes de tomar la acción de turbinado, $W_{i,t,q+1}$ representa el afluente neto (caudal de ingreso) para la presa i en la quincena $q + 1$ del año t , tales valores serán obtenidos de los datos históricos con los que ya se cuentan. Por último $k_i u_m$, $k_i \in \mathcal{K}_{i,m}$, representa el volumen de agua extraído por la acción de turbinado aplicada en la etapa hidrológica correspondiente a la quincena q .

Cuando $q = 23$, la transición se define por

$$V_{i,t+1,0} = V_{i,t,23} + W_{i,t+1,0} - k_i u_m. \quad (3.4)$$

En ambos casos, el volumen discretizado de la quincena $q + 1$ se obtiene aplicando el operador de discretización $\mathcal{D}$ al volumen resultante, es decir,

$$s'_i = \mathcal{D}(V_{i,t,q+1}, N_i),$$

mientras que la etapa hidrológica evoluciona mediante $m' = (m + 1) \bmod M$.

Por lo tanto, el estado discreto siguiente está dado por

$$s' = (s'_1, s'_2, m').$$

Desde el punto de vista de Puterman (1994), la transición de MDP se define mediante una función de probabilidad condicional

$$\mathbb{P}(s'|s, a), \quad (3.5)$$

la cual especifica la probabilidad de transicionar al estado s' dado que se tomó la acción a en el estado s .

3.1.5 Función de recompensa ($\mathcal{R}$)

3.1.5.1 Modelo hidráulico-energético linealizado

La energía generada depende del volumen de agua turbinado y una aproximación lineal de la altura hidráulica. Para cada presa i , se define la función de altura

$$H_i(s_i, s'_i) = \frac{20(s_i + s'_i + 2)}{2} = 10(s_i + s'_i + 2). \quad (3.6)$$

Tal expresión corresponde a un modelo lineal basado en estados discretizados, el término $+2$ se introdujo para evitar alturas nulas en estados con bajo volumen y el término 20 como intercepto

que representa la altura hidráulica mínima mientras que como pendiente representa cuántos metros de altura se ganan por cada incremento en el estado discretizado, es decir, la ganancia por cada incremento de Δ en el volumen de agua almacenado.

Sea $\eta = 0.9$ eficiencia de conversión hidráulica a eléctrica, y $g = 9.81 \text{ m/s}^2$ aceleración de la gravedad, entonces la energía generada por la presa i al tomar la acción a en el estado s y transicionar a s' se define por

$$E_i(s, a, s') = \frac{\eta g H_i(s_i, s'_i)(k_i u_m \times 10^6)}{3600 \times 10^6}, \quad (3.7)$$

donde 10^6 representa la conversión de Mm^3 a m^3 y 3600×10^6 la conversión de kWh a GWh .

Por lo tanto la energía total generada por el sistema es

$$E = E_1 + E_2. \quad (3.8)$$

3.1.5.2 Estructura de penalizaciones

La recompensa incorpora penalizaciones para garantizar el cumplimiento de restricciones operativas. Se definen las siguientes penalizaciones:

- Penalización por derrame: si $V_{i,t,q+1} > N_i \Delta$ se aplica

$$\Pi_{derr} = C_{derr} \cdot \left(\frac{V_{i,t,q+1} - N_i \Delta}{\Delta} \right) \quad (3.9)$$

- Penalización por déficit de agua: si $V_{i,t,q+1} < 0$ se aplica

$$\Pi_{def} = C_{def} \quad (3.10)$$

- Penalización por violación de curva guía: si $s'_i < CG_i(m)$ se aplica

$$\Pi_{CG} = C_{CG} \cdot (s'_i - CG_i(m)) \quad (3.11)$$

- Penalización por niveles críticos (casi desbordamiento): si $s'_i \geq N_i - 1$ se aplica

$$\Pi_{crit} = C_{crit} \quad (3.12)$$

donde $C_{derr}, C_{def}, C_{CG}, C_{crit}$ son constantes de penalización ajustadas empíricamente con valores 10000, 10000, 5000, 20000 respectivamente y $CG_i(m)$ representa la curva guía para la presa i en la etapa m .

La función de recompensa total se define finalmente por

$$\mathcal{R}(s, a, s') = E - \Pi_{derr} - \Pi_{def} - \Pi_{CG} - \Pi_{crit}. \quad (3.13)$$

En el presente trabajo no se modela una distribución analítica explícita, por lo que en la práctica se construye un dataset empírico basado en datos históricos. La dinámica se construye a partir de trayectorias históricas

$$(s_t, a_t, r_t, s'_{t+1})$$

en donde cada una de ellas representa una experiencia de transición observada en los datos históricos, siendo r_t el valor obtenido de la Equation 3.13, representando la recompensa obtenida al tomar la acción a_t en el estado s_t y transicionar a s'_{t+1} . Este enfoque se alinea con un esquema de *Batch Reinforcement Learning*.

3.2 Ecuación de optimalidad de Bellman

Conforme a la teoría clásica de control estocástico, por ejemplo Puterman (1994), Teorema 6.2.3, en un MDP descontado existe una única función de valor de acción óptima $V^* : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ que satisface la ecuación de optimalidad de Bellman cuando los conjuntos de estados y acciones son finitos:

$$V^*(s, a) = \mathcal{R}(s, a, s') + \gamma \sum_{s' \in \mathcal{S}} P(s'|s, a) \max_{a' \in \mathcal{A}} V^*(s', a'). \quad (3.14)$$

Dado que en lugar de una función de transición analítica se cuenta con un dataset empírico de trayectorias $(s_t, a_t, r_t, s'_{t+1})$, para todo t , la ecuación de Bellman se reformula en su versión empírica como

$$V^*(s, a) = \mathcal{R}(s, a, s') + \gamma \max_{a' \in \mathcal{A}} V^*(s', a'), \quad (3.15)$$

para más detalles consultar Ernst et al. (2005).

3.3 Aproximación numérica mediante Fitted Q-Iteration (FQI)

Si bien es sabido que la programación dinámica estocástica está afectada por la maldición de la dimensionalidad, Castelletti et al. (2010), mientras más variables de estado hayan, el requisito computacional crece exponencialmente, además de que se debe contar con un modelo de transición del sistema explícito, por ello el presente trabajo se basa en un enfoque de aproximación funcional mediante Fitted Q-Iteration (FQI), el cual es un algoritmo de aprendizaje por refuerzo que permite aproximar la función de valor de acción óptima V^* a partir de un conjunto de transiciones empíricas.

3.3.1 Iteración de Bellman empírica

Al principio, se supone una función de valor de acción inicial $V^{(0)}$ ($V^{(0)}(s, a) = 0$ para todo (s, a)). Luego, sucesivamente se generan nuevas aproximaciones para cada iteración n , actualizando la función de valor de acción mediante la ecuación de Bellman empírica. Para cada transición observada $(s_t, a_t, r_t, s'_{t+1})$ en el dataset, se define el **objetivo de Bellman** por

$$y^{(n)} := r + \gamma \max_{a' \in \mathcal{A}} V^{(n-1)}(s', a'), \quad (3.16)$$

el cual representa una estimación del valor de acción óptimo asociado al par (s, a) basada en la recompensa obtenida r y el valor de acción máximo en el estado siguiente s' según la función de valor de acción de la iteración anterior $V^{(n-1)}$.

3.3.2 Aproximación funcional por regresión no paramétrica (ExtraTrees)

Una vez calculados los objetivos de Bellman $y^{(n)}$ Equation 3.16, se ajusta una función de valor de acción $V^{(n)}$ que aproxime la relación entre los pares (s, a) y los valores objetivos $y^{(n)}$, dicha función se obtiene resolviendo un problema de aprendizaje supervisado que se explicó en la sección (pendiente).

El procedimiento se formula como un problema de regresión no paramétrica, en donde se busca encontrar una función $V^{(n)}$ que minimice el error entre las predicciones $V^{(n)}(s, a)$ y los objetivos $y^{(n)}$ para todas las transiciones $(s_t, a_t, r_t, s'_{t+1})$ en el dataset. En la práctica, se utiliza el algoritmo de *ExtraTrees*, que como propone Ernst et al. (2005), el cual argumenta que ofrece gran flexibilidad para aproximar funciones de valor en espacios continuos o de alta dimensionalidad.

La modelación mediante ExtraTrees compuesto por 300 árboles de decisión, con una profundidad máxima de 14 y un mínimo de 5 muestras por hoja. Cada árbol de decisión particiona el espacio estado-acción en regiones homogéneas, (grupo de (s, a) similares) y proporciona una estimación local de la función de valor. La predicción final corresponde al promedio de las predicciones individuales de todos los árboles de decisión.

El algoritmo de FQI se repite iterativamente hasta que la función de valor de acción converge. En la práctica se definió una métrica de convergencia empírica por

$$\Delta = \frac{1}{L} \sum_{l=1}^L |V^{(n)}(s_l, a_l) - V^{(n-1)}(s_l, a_l)|, \quad (3.17)$$

la cual se define sobre $\mathcal{T} \subset \{(s_t, a_t, r_t, s'_{t+1})\}$ siendo L la cardinalidad de $\mathcal{T}$.

Por lo que el algoritmo se detiene hasta que el $\Delta < \epsilon$, es decir, cuando el cambio entre $V^{(n)}$ y $V^{(n-1)}$ sea menor a un umbral predefinido o bien cuando se alcance un número máximo de iteraciones.

Ejemplo de un árbol de decisión




Figure 3.1: Árbol de decisión con profundidad máxima de 14 y un mínimo de 5 muestras por hoja.

3.4 Política óptima y simulación operativa

Una vez obtenida la función de valor de acción óptima V^* , se deriva la política óptima $\pi^* : \mathcal{S} \rightarrow \mathcal{A}$ que asigna a cada estado s la acción a que maximiza el valor de acción

$$\pi^*(s) := \arg \max_{a \in \mathcal{A}} V^*(s, a), \quad (3.18)$$

es decir, para cada estado s , la política óptima $\pi^*(s)$ indica la acción que se debe tomar para maximizar el valor de acción estimado.

Finalmente, se valida la política óptima π^* mediante simulación en lazo cerrado, es decir, se simula la operación del sistema hidroeléctrico utilizando la política π^* para tomar decisiones de turbinado en cada estado observado durante las trayectorias históricas.

La evaluación de la política se realiza mediante un recorrido determinista sobre la serie histórica completa. El algoritmo opera de la siguiente manera:

1. **Inicialización:** Se fijan los volúmenes iniciales $V_{1,0}$ y $V_{2,0}$.
2. **Mapeo estacional:** Para cada quincena q , se determina $m = \mu(q)$ y la unidad de extracción u_m .
3. **Discretización:**

$$s_i = \mathcal{D}(V_i, N_i), \quad i \in \{1, 2\}.$$

4. **Selección de acción:**

$$(k_1^*, k_2^*) = \arg \max_{k_1, k_2} \hat{V}^*(s, a),$$

donde

$$(s, a) = (s_1, s_2, m, k_1, k_2).$$

5. **Balance hídrico:**

$$V_{i,t,q+1} = V_{i,t,q} + W_{i,t,q+1} - k_i^* u_m.$$

6. Proyección física:

$$V_i^{\text{new}} = \min\{V_{i,t,q+1}, N_i \Delta V\},$$

$$\text{derrame}_i = \max\{0, V_{i,t,q+1} - N_i \Delta V\}.$$

7. Cálculo energético:

$$H_i = 10 \left(s_i + \mathcal{D}(V_{i,t,q+1}, N_i) + 2 \right),$$

$$E_i(s, a, s') = \frac{\eta g H_i(s_i, s'_i) (k_i^* u_m \times 10^6)}{3600 \times 10^6}.$$

8. **Registro y actualización:** Se almacenan métricas de energía, derrames y volúmenes, y se actualiza el estado para la siguiente iteración.

La metodología sigue la práctica estándar en aprendizaje por refuerzo aplicado a sistemas de control documentado en Bertsekas (2019), en el cual la política aprendida se valida mediante una simulación en lazo cerrado sobre trayectorias históricas.

3.4.1 Métricas de desempeño y validación estadística

Una vez obtenidos los resultados de la simulación en lazo cerrado, se evalúa el desempeño de la política óptima π^* utilizando métricas clave como las siguientes:

Table 3.1: Resumen del desempeño energético del sistema bajo la política óptima aprendida mediante FQI. Los valores corresponden al promedio sobre el periodo de simulación 1959–2008.

Métrica	Angostura	Malpaso	Sistema Total
Energía promedio quincenal [GWh]	242.85	139.92	382.78
Energía anual estimada [GWh]	4,857	2,798	7,656
Contribución al sistema [%]	63.4	36.6	100.0

Por otro lado, los derrames promedio quincenales y anuales se presentan en la siguiente tabla:

Table 3.2: Resumen del desempeño hídrico del sistema bajo la política óptima aprendida mediante FQI. Los valores corresponden al promedio sobre el periodo de simulación 1959–2008.

Métrica	Angostura	Malpaso	Sistema Total
Derrame total [Mm ³]	7,722.10	26,330.80	34,052.90
Derrame promedio Anual [Mm ³]	154.44	526.62	681.06

De acuerdo con los resultados obtenidos y con la información obtenida de Díaz (2010), se observa que la política no está gestionando adecuadamente los recursos hídricos, ya que el volumen de agua derramada es considerablemente alto, lo que sugiere que la política aprendida no está optimizando eficientemente el uso del agua disponible para generación energética. Además, la contribución energética de cada presa al sistema total no refleja un balance adecuado, lo que podría indicar que la política está favoreciendo excesivamente una presa sobre la otra, lo que no es deseable desde el punto de vista de la gestión integrada del sistema hidroeléctrico. Estos resultados sugieren que la política óptima aprendida mediante FQI no está logrando un equilibrio adecuado entre la generación de energía y la gestión eficiente del recurso hídrico, lo que podría requerir una revisión de la formulación del problema, la función de recompensa o la metodología de aprendizaje utilizada para mejorar el desempeño del sistema en términos de ambos objetivos.

3.5 Conclusiones del capítulo

- Síntesis de contribuciones matemáticas y numéricas.
- Reafirmación de la coherencia entre formulación teórica, implementación algorítmica y validación operativa.
- Declaración de cierre alineada con los objetivos de la tesis.

4

5

Referencias

- Bertsekas, Dimitri P. 2019. *Reinforcement Learning and Optimal Control*. Athena Scientific.
- Castelletti, A., S. Galelli, M. Restelli, and R. Soncini-Sessa. 2010. “Tree-Based Reinforcement Learning for Optimal Water Reservoir Operation.” *Water Resources Research* 46: W09507. <https://doi.org/10.1029/2009WR008898>.
- Díaz, Arallely Alegría. 2010. “Política de Operación Óptima Del Sistema de Presas Del Río Grijalva. Efectos de La Curva Guía.” Tesis de Maestría en Ingeniería Civil -- Hidráulica, Universidad Nacional Autónoma de México, Facultad de Ingeniería.
- Ernst, Damien, Pierre Geurts, and Louis Wehenkel. 2005. “Tree-Based Batch Mode Reinforcement Learning.” *Journal of Machine Learning Research* 6: 503–56. <http://www.jmlr.org/papers/volume6/ernst05a/ernst05a.pdf>.
- IBM. 2025. “¿Qué es el aprendizaje por refuerzo?” IBM. https://www.ibm.com/mx-es/think/topics/reinforcement-learning?mhsrc=ibmsearch_a&mhq=aprendizaje%20por%20refuerzo.
- Puterman, Martin L. 1994. *Markov Decision Processes: Discrete Stochastic Dynamic Programming*. Wiley Series in Probability and Statistics. John Wiley & Sons. <https://doi.org/10.1002/9780470316887>.